ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Phùng Trường Trinh

Nghiên Cứu Phân Đoạn Ảnh Bông Lúa Đa Giống Kết Hợp Kỹ Thuật Trí Tuệ Nhân Tạo Có Khả Năng Giải Thích

BÁO CÁO TIỂU LUẬN

MÔN: CHỦ ĐỀ HIỆN ĐẠI VỀ HỆ THỐNG THÔNG TIN

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Phùng Trường Trinh

Nghiên Cứu Phân Đoạn Ảnh Bông Lúa Đa Giống Kết Hợp Kỹ Thuật Trí Tuệ Nhân Tạo Có Khả Năng Giải Thích

BÁO CÁO TIỂU LUẬN

MÔN: CHỦ ĐỀ HIỆN ĐẠI VỀ HỆ THỐNG THÔNG TIN

Giảng viên hướng dẫn: PGS. TS. Hà Quang Thuỵ

HÀ NỘI - 2026

MỤC LỤC

MỤC LỤC i
DANH MỤC HÌNH ẢNH iii
DANH MỤC CÁC BẢNG iv
DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT v
CHƯƠNG 1 TỔNG QUAN VÀ GIỚI THIỆU BÀI BÁO 1
1.1. Đặt vấn đề và bối cảnh nghiên cứu 1
1.2. Giới thiệu bài báo gốc 1
1.3. Hồ sơ khoa học của nhóm tác giả 2
1.3.1. Tác giả liên hệ: Xiangchao Gan 2
1.3.2. Nhóm tác giả chính 3
CHƯƠNG 2 PHÂN TÍCH NỘI DUNG VÀ MỞ RỘNG 4
2.1. Phát biểu bài toán 4
2.1.1. Bối cảnh và thách thức 4
2.1.2. Hình thức hóa bài toán 4
2.2. Phân tích các giải pháp kỹ thuật 5
2.3. Tổng quan các nghiên cứu liên quan và hướng phát triển kế thừa 6
2.3.1. Các nghiên cứu nền tảng quan trọng 6
2.3.2. Các nghiên cứu kế thừa và xu hướng mới nổi 6
2.3.3. Liên hệ với bối cảnh nghiên cứu của luận văn 7
CHƯƠNG 3 THỰC NGHIỆM VÀ ĐÁNH GIÁ 8
3.1. Thiết lập môi trường và công cụ thực nghiệm 8
3.2. Bộ dữ liệu CVRP 8
3.2.1. Tổng quan bộ dữ liệu 8
3.2.2. Phân chia dữ liệu và mất cân bằng lớp 9
3.3. Tái tạo thực nghiệm phân đoạn ngữ nghĩa 10
3.3.1. Các mô hình đánh giá và cấu hình huấn luyện 10
3.3.2. Kết quả định lượng 11

3.3.3. Kết quả định tính 14
3.4. Ứng dụng Trí tuệ nhân tạo Giải thích được (xAI).....17
3.4.1. Tổng quan về Trí tuệ nhân tạo Giải thích được.....17
3.4.2. Phương pháp Saliency-based: GradCAM++ và EigenCAM.....18
3.4.3. Định lượng chất lượng giải thích - Energy Pointing Game.....20
3.4.4. So sánh cơ chế chú ý: CNN đối với Transformer.....20
3.4.5. Phân tích các trường hợp thất bại thông qua xAI nhằm trả lời câu hỏi nghiên cứu số 3 (RQ3) 21
3.5. Thực nghiệm bổ sung 22
3.5.1. Phân đoạn hạt lúa với SAM ViT-H 22
3.5.2. Tái tạo 3D cây lúa.....24
3.6. Thảo luận 25
3.6.1. Độ tin cậy của thực nghiệm tái tạo 25
3.6.2. Đóng góp của xAI vào hiểu biết mô hình.....25
3.6.3. Giới hạn và hướng cải thiện.....25
TÀI LIỆU THAM KHẢO.....27
PHỤ LỤC: BẢN DỊCH BÀI BÁO 29

DANH MỤC HÌNH ẢNH

STT	Nội dung
Hình 3.1	Ví dụ đa góc nhìn của giống T178 — bốn góc nhìn nadir, oblique, side và close-up
Hình 3.2	Ví dụ annotation cho 6 giống ngẫu nhiên (đỏ = bông lúa được gán nhãn)
Hình 3.3	Phân bố tỉ lệ pixel bông lúa theo tập dữ liệu (train / val / field test)
Hình 3.4	Phân bố số ảnh mỗi giống: giống G (landrace, n=50) và giống T (modern cultivar, n=232)
Hình 3.5	Đường cong training loss và val mIoU theo iteration của bốn mô hình
Hình 3.6	So sánh Panicle IoU: kết quả thực nghiệm vs. bài báo gốc trên tập val và field test
Hình 3.7	Radar chart so sánh tổng thể bốn mô hình trên val set và field test
Hình 3.8	So sánh kết quả phân đoạn của bốn mô hình trên val set (xanh=TP, đỏ=FP, vàng=FN)
Hình 3.9	Các trường hợp phân đoạn thành công của Mask2Former trên tập val
Hình 3.10	Các trường hợp thất bại trên field test: cỏ dại, lá lúa, bông nhỏ, che khuất nặng
Hình 3.11	Heatmap xAI — GradCAM++ và EigenCAM cho bốn mô hình, kèm EPG score
Hình 3.12	So sánh cơ chế chú ý: CNN (GradCAM++) vs. Transformer (EigenCAM)
Hình 3.13	So sánh tỉ lệ hạt phát hiện: SAM ViT-H vs. kết quả bài báo gốc
Hình 3.14	SAM ViT-H phân đoạn hạt lúa — bông tự nhiên (hanging)
Hình 3.15	SAM ViT-H phân đoạn hạt lúa — bông mở ra (unfolded)
Hình 3.16	Số hạt phát hiện theo từng giống lúa
Hình 3.17	Tái tạo 3D ba giống lúa G1204, G1210, G1224

DANH MỤC CÁC BẢNG

STT	Nội dung
Bảng 3.1	Thống kê chi tiết bộ dữ liệu CVRP sử dụng trong thực nghiệm
Bảng 3.2	Cấu hình huấn luyện chung cho bốn mô hình phân đoạn ngữ nghĩa
Bảng 3.3	Kết quả phân đoạn trên tập val (multi-cultivar) - tái tạo Bảng 2 của bài báo gốc
Bảng 3.4	Kết quả phân đoạn trên tập field test (cảnh đồng ruộng) - tái tạo Bảng 3 của bài báo gốc
Bảng 3.5	Energy Pointing Game (EPG) score - định lượng chất lượng giải thích xAI cho bốn mô hình
Bảng 3.6	Kết quả phân đoạn hạt lúa bằng SAM ViT-H - so sánh với tỉ lệ phát hiện của bài báo gốc

DANH MỤC CÁC KÝ HIỆU, TỪ VIẾT TẮT

Từ viết tắt	Tiếng Anh	Tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
ASPP	Atrous Spatial Pyramid Pooling	Tổng hợp kim tự tháp không gian lỗ
CAM	Class Activation Map	Bản đồ kích hoạt lớp
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
CVRP	Cultivar and View Rice Panicle	Bộ dữ liệu bông lúa đa giống đa góc nhìn
EPG	Energy Pointing Game	Trò chơi chỉ điểm năng lượng
FN	False Negative	Âm tính giả
FP	False Positive	Dương tính giả
GWHD	Global Wheat Head Detection	Phát hiện đầu lúa mì toàn cầu
IoU	Intersection over Union	Giao trên hợp
MAE	Mean Absolute Error	Sai số tuyệt đối trung bình
MCMC	Markov Chain Monte Carlo	Chuỗi Markov Monte Carlo
mIoU	Mean Intersection over Union	IoU trung bình
MLP	Multilayer Perceptron	Perceptron đa lớp
MVS	Multiview Stereo	Lập thể đa góc nhìn
OSTRA	One-Stop 3D Target Reconstruction	Tái tạo mục tiêu 3D một điểm dừng
SAM	Segment Anything Model	Mô hình phân đoạn vạn năng
SLIC	Simple Linear Iterative Clustering	Phân cụm lặp tuyến tính đơn giản
SOTA	State of the Art	Tiên tiến nhất hiện tại
SVD	Singular Value Decomposition	Phân rã giá trị kỳ dị
TN	True Negative	Âm tính thật

TP	True Positive	Dương tính thật
UAV	Unmanned Aerial Vehicle	Thiết bị bay không người lái
ViT	Vision Transformer	Transformer thị giác
xAI	Explainable Artificial Intelligence	Trí tuệ nhân tạo giải thích được

CHƯƠNG 1 TỔNG QUAN VÀ GIỚI THIỆU BÀI BÁO

1.1. Đặt vấn đề và bối cảnh nghiên cứu

Lúa (Oryza sativa) là cây lương thực chủ yếu, cung cấp dinh dưỡng thiết yếu cho hơn một nửa dân số thế giới [1]. Trong bối cảnh biến đổi khí hậu và áp lực gia tăng dân số toàn cầu, việc nâng cao năng suất và chất lượng giống lúa trở thành nhiệm vụ cấp bách của ngành nông nghiệp hiện đại. Đặc tính kiểu hình (phenomics) của bông lúa, bao gồm số hạt, hình dạng, cấu trúc bông và mật độ là những chỉ số quan trọng phản ánh tiềm năng năng suất của từng giống, đóng vai trò then chốt trong công tác chọn giống và canh tác [1], [2].

Tuy nhiên, các phương pháp thu thập dữ liệu kiểu hình truyền thống vẫn phụ thuộc phần lớn vào quan sát và đo lường thủ công - một quy trình tốn kém công sức, mất nhiều thời gian và dễ mắc lỗi do yếu tố chủ quan của người đánh giá [2]. Phenomics thực vật (Plant Phenomics), kết hợp giữa học máy và thị giác máy tính, đã và đang được áp dụng ngày càng rộng rãi như một giải pháp tự động hóa hiệu quả, giúp rút ngắn đáng kể thời gian và chi phí trong nghiên cứu chọn giống [2], [3].

Mặc dù nhiều phương pháp học sâu tiên tiến đã được phát triển cho nhận dạng và phân đoạn bông lúa [4], [5], một thách thức căn bản vẫn tồn tại: sự thiếu hụt trầm trọng các bộ dữ liệu ảnh công khai, đa dạng giống và có annotation (nhãn phân đoạn) chất lượng cao. Thực tế, bông lúa có sự biến đổi lớn về màu sắc, kết cấu, kích thước và hình dạng tùy theo giống và điều kiện môi trường - bao gồm ánh sáng không đều, nền ảnh phức tạp và hiện tượng che khuất (occlusion) giữa các cây [2]. Điều này khiến việc xây dựng bộ dữ liệu đủ phong phú và chất lượng cao trở nên vô cùng khó khăn, đồng thời cản trở sự phát triển của các mô hình AI chuyên biệt cho lĩnh vực phenomics lúa. Đơn cử, Xiong và cộng sự [2] chỉ có thể kiểm thử trên 48 mẫu với độ chính xác phân đoạn ~80%, phản ánh rõ ràng sự giới hạn về quy mô và tính đại diện của dữ liệu hiện có.

Một khoảng trống nghiên cứu đặc biệt cần được lấp đầy là việc thiếu các bộ dữ liệu có khả năng phân biệt đặc điểm bông lúa theo từng giống (cultivar-specific), hỗ trợ nhận dạng giống tự động và đếm hạt chính xác theo từng bông [6] - những tác vụ có yêu cầu phân giải cao và tính chi tiết vượt trội so với phân đoạn bông lúa thông thường. Ngoài ra, hầu hết các nghiên cứu hiện tại chỉ thu thập ảnh từ một góc nhìn cố định hoặc ở độ phân giải thấp [7], [8], dẫn đến mô hình thiếu khả năng tổng quát hóa khi triển khai trong điều kiện đồng ruộng thực tế.

1.2. Giới thiệu bài báo gốc

Để giải quyết các thách thức nêu trên, tiểu luận này tập trung nghiên cứu và phân tích bài báo khoa học mang tính khảo sát nền tảng:

Tên bài báo: "CVRP: A Rice Image Dataset with High-Quality Annotations for Image Segmentation and Plant Phenomics Research" (CVRP: Bộ Dữ Liệu Hình Ảnh Lúa Với Annotation Chất Lượng Cao Cho Phân Đoạn Ảnh và Nghiên Cứu Phenomics Thực Vật).

Nơi công bố: Bài báo được công bố trên tạp chí Plant Phenomics, tập 7, năm 2025 (Plant Phenomics 7 (2025) 100025). Đây là tạp chí thuộc nhà xuất bản Elsevier, do Đại học Nông nghiệp Nam Kinh (Nanjing Agricultural University) đồng xuất bản, nằm trong danh sách Q1 của lĩnh vực Nông học và Khoa học Thực vật. Bài báo thuộc định dạng Data Article - một dạng bài chuyên công bố và mô tả chi tiết về bộ dữ liệu khoa học mở.

DOI: https://doi.org/10.1016/j.plaphe.2025.100025

Ngày công bố: Nhận bản thảo: 27/09/2024; Chấp nhận đăng: 08/02/2025; Công bố trực tuyến: 01/03/2025.

Đóng góp chính của bài báo: Bài báo đề xuất và công bố bộ dữ liệu ảnh lúa đa giống, đa góc nhìn (CVRP) với các đóng góp nổi bật sau:

- Xây dựng bộ dữ liệu CVRP gồm 2.303 ảnh đồng ruộng có annotation và 123 ảnh bông lúa trong nhà, thu thập từ 231 giống địa phương (landraces) và 50 giống hiện đại - quy mô và độ đa dạng giống lớn nhất từ trước đến nay trong lĩnh vực này.
- Thiết kế quy trình annotation bán tự động (semi-automatic) hai giai đoạn, kết hợp giữa công cụ LabelMe thủ công và mô hình Mask2Former học sâu, giúp giảm thiểu thời gian và chi phí annotation đáng kể.
- Đánh giá toàn diện hiệu năng của bốn mô hình phân đoạn ngữ nghĩa SOTA (DeepLabV3+, Mask2Former, SegFormer, K-Net) trên bộ dữ liệu CVRP.
- Chứng minh khả năng ứng dụng mở rộng của CVRP vào các tác vụ phức tạp như: nhận dạng giống lúa tự động, đếm bông và đếm hạt, tái tạo cây 3D (3D reconstruction).

1.3. Hồ sơ khoa học của nhóm tác giả

Bài báo là sản phẩm nghiên cứu của nhóm tác giả đến từ Phòng thí nghiệm Trọng điểm Quốc gia về Di truyền, Nguồn gen và Cải tiến Giống cây trồng (State Key Laboratory for Crop Genetics and Germplasm Enhancement and Utilization), thuộc Đại học Nông nghiệp Nam Kinh (Nanjing Agricultural University), Trung Quốc. Nhóm có chuyên môn liên ngành sâu rộng, kết hợp giữa di truyền học thực vật, phenomics và trí tuệ nhân tạo:

1.3.1. Tác giả liên hệ: Xiangchao Gan

Đơn vị công tác: State Key Laboratory for Crop Genetics and Germplasm Enhancement and Utilization; College of Artificial Intelligence, Nanjing Agricultural University, Nanjing, 210095, Trung Quốc; đồng thời là thành viên của Zhongshan Biological Breeding Laboratory, Nanjing.

Email liên hệ: gan@njau.edu.cn

Vai trò: Là người thiết kế toàn bộ nghiên cứu, đồng thời là tác giả phụ trách viết và hoàn thiện bản thảo. Gan là nhà khoa học hoạt động ở giao điểm giữa Trí tuệ nhân tạo và Phenomics thực vật, tập trung vào việc ứng dụng thị giác máy tính cho phân tích hình ảnh cây trồng và nghiên cứu chọn giống lúa. Nhóm nghiên cứu của ông đã phát triển khung tái tạo 3D thực vật (OSTRA framework) được ứng dụng trực tiếp trong bài báo này.

1.3.2. Nhóm tác giả chính

Bài báo có ba tác giả đồng đóng góp ngang nhau (co-first authors), phản ánh tính chất liên ngành và phân công chuyên biệt của công trình:

Zhiyan Tang: Chịu trách nhiệm xử lý dữ liệu, huấn luyện mô hình mạng nơ-ron, annotation ảnh và kiểm duyệt dữ liệu (data curation). Đây là tác giả thực hiện phần kỹ thuật trọng tâm nhất của bài báo, xây dựng quy trình gán nhãn bán tự động và đánh giá các mô hình phân đoạn. Tang cũng là tác giả chính viết bản thảo cùng với Gan.

Jiandong Sun: Chịu trách nhiệm thu thập dữ liệu thực địa, gán nhãn ảnh và kiểm duyệt dữ liệu tại đồng ruộng Nanjing.

Yunlu Tian: Chịu trách nhiệm canh tác cây lúa và thu thập dữ liệu, đảm bảo tính đa dạng giống và chất lượng mẫu trong toàn bộ mùa vụ.

Ngoài ra, các tác giả Jiexiong Xu và Weikun Zhao đóng góp vào tái tạo 3D và huấn luyện mô hình; Gang Jiang phụ trách thu thập giống cây; Jiaqi Deng đóng góp vào tái tạo 3D.

CHƯƠNG 2 PHÂN TÍCH NỘI DUNG VÀ MỞ RỘNG

2.1. Phát biểu bài toán

2.1.1. Bối cảnh và thách thức

Bài toán nghiên cứu xuất phát từ một mâu thuẫn cốt lõi trong lĩnh vực phenomics thực vật: các mô hình học sâu tiên tiến đòi hỏi lượng lớn dữ liệu ảnh được gán nhãn chính xác để hoạt động hiệu quả, trong khi việc xây dựng các bộ dữ liệu như vậy lại đặc biệt khó khăn đối với bông lúa.

Bông lúa là cơ quan sinh sản phức tạp, biểu hiện sự khác biệt đáng kể về hình thái tùy theo thông tin di truyền và điều kiện môi trường. Trong ảnh đồng ruộng thực tế, bông lúa bị ảnh hưởng bởi nhiều yếu tố gây khó khăn cho phân đoạn tự động: phản chiếu ánh sáng từ mặt nước ruộng, sự mất cân bằng ánh sáng do thời tiết, nền ảnh lộn xộn gồm lá lúa và cỏ dại, hiện tượng che khuất giữa các cây do mật độ trồng dày và sự tương đồng màu sắc giữa bông lúa với lá và cỏ dại.

Thách thức đặc trưng của lĩnh vực này còn nằm ở chỗ hầu hết các nghiên cứu trước đây chỉ thu thập dữ liệu từ một hoặc hai giống lúa, bỏ qua sự đa dạng kiểu hình giữa các giống, điều vô cùng quan trọng khi mục tiêu là xây dựng mô hình AI có khả năng tổng quát hóa cho toàn bộ không gian di truyền của loài. Việc gán nhãn thủ công cho dữ liệu bông lúa cũng cực kỳ tốn công sức do cấu trúc bông phức tạp, kích thước hạt nhỏ và sự chồng chéo giữa các bộ phận.

2.1.2. Hình thức hóa bài toán

Bài toán được hình thức hóa như sau: Cho tập ảnh $X = \{x_1, x_2, ..., x_n\}$ là ảnh lúa thu thập trong điều kiện thực địa đa dạng, cần xây dựng hàm phân đoạn $f: X \rightarrow Y$ trong đó $Y = \{y_1, y_2, ..., y_n\}$ là tập bản đồ nhãn phân đoạn, với mỗi pixel được gán nhãn thuộc bông lúa hoặc nền:

Để bài toán có thể giải được bằng học sâu, cần thỏa mãn đồng thời hai điều kiện: (1) có đủ lượng dữ liệu ảnh được gán nhãn chính xác để huấn luyện mô hình và (2) dữ liệu đó đủ đa dạng về giống lúa, góc chụp, điều kiện ánh sáng và giai đoạn sinh trưởng để mô hình học được các đặc trưng tổng quát. Bài báo nhận diện rằng điều kiện (1) và (2) đều chưa được đáp ứng trong các bộ dữ liệu hiện có - đây chính là lý do tồn tại của CVRP.

Đặc biệt, bài báo mở rộng bài toán từ phân đoạn bông lúa thông thường sang các tác vụ đòi hỏi phân giải cao hơn: nhận dạng giống lúa dựa trên đặc điểm bông và đếm hạt theo từng bông. Đây là những bài toán phân loại và đếm đối tượng nhỏ trong điều

kiện ảnh phức tạp, yêu cầu mô hình nắm bắt được cả đặc trưng cục bộ lẫn ngữ cảnh toàn cục của từng giống.

2.2. Phân tích các giải pháp kỹ thuật

Để giải quyết các thách thức trên, bài báo đề xuất hai nhóm giải pháp kỹ thuật chính: quy trình xây dựng, gán nhãn dữ liệu và khung đánh giá mô hình phân đoạn.

Giải pháp 1: Quy trình thu thập dữ liệu đa giống, đa góc nhìn

Nhóm tác giả thiết kế một quy trình thu thập ảnh có hệ thống nhằm đảm bảo tính đa dạng tối đa. Dữ liệu được thu thập tại đồng ruộng lúa ở Nam Kinh, Trung Quốc, trong giai đoạn chín, khi bông lúa đã lộ ra đầy đủ và đặc trưng nhất. Mẫu gồm 231 giống địa phương và 50 giống hiện đại, mỗi giống được chụp ảnh độc lập với kỹ thuật quay vòng xoắn ốc để bao phủ nhiều góc nhìn: nadir (nhìn từ trên xuống), oblique (nghiêng), side (ngang) và close-up (cận cảnh). Bốn tấm bảng nhựa với họa tiết độc đáo được sử dụng để tách biệt các cây kề nhau, vừa giảm ảnh hưởng của che khuất, vừa cung cấp điểm đặc trưng phục vụ tái tạo 3D sau này.

Giải pháp 2: Quy trình gán nhãn bán tự động hai giai đoạn

Đây là đóng góp kỹ thuật trọng tâm của bài báo. Thay vì gán nhãn hoàn toàn thủ công, vốn cực kỳ tốn thời gian (352 giờ chỉ cho 807 ảnh đầu tiên), nhóm tác giả thiết kế quy trình hai giai đoạn kết hợp:

• **Giai đoạn 1 (thủ công)**: 807 ảnh đồng ruộng được gán nhãn thủ công qua công cụ LabelMe với hình dạng đa giác, đảm bảo độ chính xác cao cho đường viền phức tạp của bông lúa. Dữ liệu này được dùng để huấn luyện mô hình phân đoạn.

• **Giai đoạn 2 (Model assisted)**: Mô hình Mask2Former được huấn luyện trên dữ liệu thủ công và được dùng để tự động dự đoán gán nhãn cho phần ảnh còn lại. Các dự đoán sau đó trải qua quá trình kiểm duyệt thủ công với mức độ điều chỉnh tối thiểu (~1 phút/ảnh), giúp rút ngắn thời gian gán đáng kể.

Sự lựa chọn Mask2Former làm mô hình annotation trợ giúp là có cơ sở: kiến trúc này sử dụng cơ chế masked attention, tập trung cross-attention vào vùng mask dự đoán kết hợp với module trích xuất đặc trưng độ phân giải cao, cho phép phân đoạn chính xác các chi tiết mịn của bông lúa. Backbone Swin Transformer giúp nắm bắt thông tin đa tỷ lệ, đặc biệt phù hợp với bài toán có nhiều mức chi tiết từ toàn cây đến từng hạt.

Giải pháp 3: Đánh giá toàn diện các mô hình phân đoạn SOTA

Bài báo đánh giá bốn mô hình phân đoạn ngữ nghĩa tiêu biểu trên CVRP thông qua framework MMSegmentation:

• **DeepLabV3+**: Sử dụng module ASPP (Atrous Spatial Pyramid Pooling) để nắm bắt ngữ cảnh đa tỷ lệ thông qua tích chập lỗ, dựa trên backbone ResNet.

• **Mask2Former**: Kiến trúc transformer với masked attention và trích xuất đặc trưng độ phân giải cao, backbone Swin Transformer đạt IoU tốt nhất trên dữ liệu đa giống.

• **SegFormer**: Kết hợp encoder Mix Vision Transformer phân cấp với decoder MLP nhẹ; không cần interpolation positional encoding, linh hoạt với nhiều độ phân giải.

• **K-Net**: Giới thiệu cơ chế sinh kernel động (dynamic kernel generation) để nắm bắt đặc trưng của các đối tượng khác nhau; backbone Swin Transformer.

Các chỉ số đánh giá được sử dụng bao gồm Precision, Recall, F-score và IoU, tất cả đều tính riêng cho lớp bông lúa (không trung bình với nền) do sự mất cân bằng lớp lớn. Kết quả cho thấy Mask2Former đạt IoU cao nhất (73,38% trên dữ liệu đa giống; 76,56% trên dữ liệu cảnh đồng ruộng), khẳng định ưu thế của kiến trúc attention-based trong bài toán phân đoạn bông lúa phức tạp.

2.3. Tổng quan các nghiên cứu liên quan và hướng phát triển kế thừa

2.3.1. Các nghiên cứu nền tảng quan trọng

CVRP được xây dựng dựa trên nền tảng của nhiều công trình tiên phong trong lĩnh vực phenomics thực vật và phân đoạn bông lúa:

Panicle-SEG (Xiong và cộng sự, 2017) [2]: Phương pháp phân đoạn ảnh bông lúa đồng ruộng kết hợp học sâu và tối ưu hóa superpixel. Được bài báo tham chiếu như một trong những công trình nền tảng, nhưng bị giới hạn ở quy mô nhỏ, chỉ 48 mẫu với độ chính xác ~80%, chứng tỏ nhu cầu về bộ dữ liệu quy mô lớn hơn.

WSUNet (Xiao và cộng sự, 2023) [4]: Phương pháp tích hợp kết nối bỏ qua có trọng số vào UNet để cải thiện phân đoạn bông lúa từ ảnh UAV mà không tăng chi phí tính toán. Đây là đại diện cho hướng tiếp cận tối ưu hóa kiến trúc CNN cho bài toán này.

GWHD Dataset (David và cộng sự, 2021) [9]: Bộ dữ liệu phát hiện đầu lúa mì toàn cầu - ví dụ tiêu biểu về bộ dữ liệu cây trồng quy mô lớn, đa dạng địa lý và chất lượng cao. CVRP kế thừa triết lý xây dựng bộ dữ liệu toàn diện của GWHD nhưng tập trung vào bài toán phân đoạn thay vì phát hiện.

Paddy Rice Dataset (Wang và cộng sự, 2021) [7]: Bộ dữ liệu ảnh UAV của ruộng lúa với phương pháp huấn luyện bán giám sát sử dụng Mask R-CNN.

2.3.2. Các nghiên cứu kế thừa và xu hướng mới nổi

Dựa trên CVRP, các hướng nghiên cứu kế thừa đang nổi lên theo hai luồng chính:

SAM/SAM2 cho Phenomics Thực Vật: Bài báo đã thử nghiệm Segment Anything Model (SAM) và SAM2 trên tập ảnh bông lúa trong nhà để phân đoạn hạt. Kết quả cho thấy SAM đạt 83% độ phủ hạt trong trạng thái bông được trải thẳng và 73% với bông ở trạng thái treo tự nhiên. Đây mở ra hướng tinh chỉnh (fine-tuning) SAM trên dữ liệu CVRP để cải thiện đáng kể hiệu năng phân đoạn hạt - một tác vụ vô cùng có giá trị cho nghiên cứu năng suất lúa.

Tái tạo cây 3D phục vụ Phenomics: Framework OSTRA đã được ứng dụng thành công để tái tạo 3D đầy đủ cho ba giống lúa từ chuỗi ảnh đa góc nhìn, với bông lúa được tô màu dựa trên nhãn. Đây là bước tiến quan trọng hướng tới đo lường kiểu hình 3D tự động, cho phép đánh giá số lượng bông, góc nghiêng và cấu trúc không gian của cây, những đặc điểm không thể đo được từ ảnh 2D.

Hybrid Transformer-CNN cho phân đoạn bông lúa: Kết quả thực nghiệm cho thấy các kiến trúc dựa trên Transformer (Mask2Former, SegFormer, K-Net với backbone Swin) vượt trội CNN thuần túy (DeepLabV3+/ResNet). Xu hướng tiếp theo là thiết kế các mô hình lai ghép (hybrid) kết hợp CNN cho trích xuất đặc trưng cục bộ (texture của hạt) với Transformer cho nhận thức ngữ cảnh toàn cục (phân biệt giống), đặc biệt phù hợp cho tác vụ nhận dạng giống lúa với độ phân giải cao.

2.3.3. Liên hệ với bối cảnh nghiên cứu của luận văn

Hướng nghiên cứu của luận văn tập trung vào bài toán phân đoạn bông lúa từ ảnh UAV, lấy bộ dữ liệu Paddy Rice Imagery Dataset của Wang và cộng sự làm tập dữ liệu huấn luyện và đánh giá chính. Tuy nhiên, bộ dữ liệu này chỉ bao phủ hai giống lúa, giới hạn đáng kể khả năng kiểm định độ tổng quát hóa của mô hình trong điều kiện thực địa đa dạng hơn.

Trong bối cảnh đó, CVRP đóng vai trò là tập dữ liệu đánh giá chéo bổ sung quan trọng. Với 2.303 ảnh từ 281 giống lúa, đa dạng về hình thái bông, góc nhìn và điều kiện ánh sáng, CVRP cho phép học viên kiểm định liệu mô hình huấn luyện trên dữ liệu Wang và cộng sự có duy trì được độ chính xác khi gặp phổ giống lúa rộng hơn hay không, một bước đánh giá mà tập dữ liệu gốc không thể tự cung cấp.

Bên cạnh đó, quy trình gán nhãn bán tự động của CVRP là tham chiếu phương pháp luận hữu ích để học viên mở rộng dữ liệu thực nghiệm khi cần; còn kết quả so sánh bốn mô hình SOTA trên CVRP cung cấp nền quan trọng cho việc lựa chọn kiến trúc phân đoạn phù hợp. Ngoài ra, phân tích lỗi có hệ thống trong bài báo chỉ ra các trường hợp nhầm lẫn giữa bông lúa, lá và cỏ dại đặt nền tảng trực tiếp cho việc áp dụng các kỹ thuật xAI nhằm giải thích hành vi mô hình trong luận văn.

CHƯƠNG 3 THỰC NGHIỆM VÀ ĐÁNH GIÁ

3.1. Thiết lập môi trường và công cụ thực nghiệm

Toàn bộ thực nghiệm được thực hiện trên một máy tính đơn nhân với GPU NVIDIA RTX 2080 Ti (12 GB VRAM), CPU Intel Core i9, RAM 64 GB, hệ điều hành Ubuntu 22.04 LTS. Framework chính sử dụng là MMSegmentation v1.2.2 - bộ công cụ phân đoạn ngữ nghĩa mã nguồn mở của OpenMMLab, được xây dựng trên nền tảng PyTorch 2.1 và CUDA 11.8. Các thư viện xAI bổ sung gồm pytorch-grad-cam để triển khai GradCAM++ và EigenCAM, cùng với segment-anything (Meta AI).

Mã nguồn thực nghiệm, cấu hình huấn luyện và kết quả định lượng được công bố công khai tại kho lưu trữ GitHub để phục vụ tái tạo và mở rộng nghiên cứu. Đường dẫn kho lưu trữ mã nguồn: https://github.com/PhungTrinhUET/ExplainableAI-CVRP-Segmentation

3.2. Bộ dữ liệu CVRP

3.2.1. Tổng quan bộ dữ liệu

Bộ dữ liệu CVRP [8] được thu thập tại đồng ruộng lúa nước ở Nam Kinh, Trung Quốc, bao gồm 231 giống địa phương (landraces) và 50 giống hiện đại (modern cultivars). Trong thực nghiệm này, đề tài xác định được 282 giống khác nhau (50 giống G - landrace và 232 giống T - modern cultivar) với tổng cộng 2.428 ảnh và 2.305 nhãn phân đoạn. Cấu trúc chi tiết của bộ dữ liệu được thống kê trong Bảng 3.1.

Bảng 3.1. Thống kê chi tiết bộ dữ liệu CVRP sử dụng trong thực nghiệm.

Loại dữ liệu	Số giống	Số ảnh	Số nhãn	Kích thước
Multi-cultivar (G - landrace)	50	400	400	1080×1920
Multi-cultivar (T - modern)	232	1.805	1.805	1080×1920
Field scenes	—	100	100	Biến đổi
Indoor panicle	41	123	—	1500×2007
TỔNG	**282**	**2.428**	**2.305**	**—**

Mỗi giống lúa được chụp trung bình 8,0 ảnh (giống G) và 7,8 ảnh (giống T) từ bốn góc nhìn khác nhau: nadir (nhìn từ trên xuống), oblique (nghiêng), side (ngang) và close-up (cận cảnh). Hình 3.1 minh họa ví dụ bốn góc nhìn của cùng một giống T178, cho thấy sự đa dạng về góc độ và cấu trúc hình ảnh mà bộ dữ liệu cung cấp.

Hình 3.1. Ví dụ đa góc nhìn của giống T178.

Nhãn được lưu dưới dạng Palette PNG với hai giá trị nhãn: 0 (nền) và 1 (bông lúa). Hình 3.2 minh họa ví dụ nhãn cho sáu giống ngẫu nhiên, cho thấy sự đa dạng về hình thái bông giữa các giống - từ bông thẳng đứng đến bông cong dài, từ bông dày đặc đến bông thưa. Đây là thách thức chính đặt ra cho các mô hình phân đoạn ngữ nghĩa khi phải tổng quát hóa trên phổ giống rộng.

Hình 3.2. Ví dụ nhãn cho 6 giống ngẫu nhiên (đỏ là bông lúa được gán nhãn).

3.2.2. Phân chia dữ liệu và mất cân bằng lớp

Dữ liệu được phân chia thành ba tập với mục đích khác nhau: (1) tập train gồm 2.116 ảnh multi-cultivar phục vụ huấn luyện, (2) tập val gồm 80 ảnh multi-cultivar để đánh giá trong quá trình huấn luyện và tái tạo Bảng 2 của bài báo gốc, và (3) tập field test gồm 100 ảnh cảnh đồng ruộng tự nhiên để kiểm định khả năng tổng quát hóa và tái tạo Bảng 3 của bài báo gốc.

Một đặc điểm nổi bật của CVRP là sự mất cân bằng lớp nghiêm trọng: tỉ lệ pixel bông lúa chỉ chiếm trung bình khoảng 7% tổng số pixel trên tập train và val, trong khi tập field test có tỉ lệ cao hơn đáng kể (trung bình ~15%) do góc chụp gần hơn. Hình 3.3 thể hiện phân bố tỉ lệ pixel bông theo từng tập dữ liệu. Để xử lý mất cân bằng này, đề tài áp dụng class weight [0.3, 3.0] cho lớp nền và bông tương ứng trong quá trình huấn luyện.

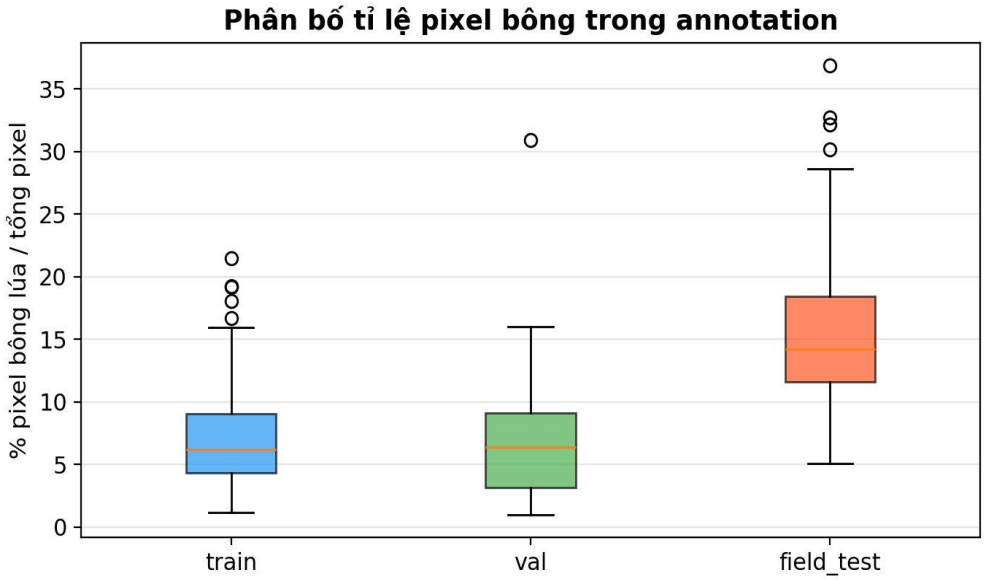

Hình 3.3. Phân bố tỉ lệ pixel bông lúa theo tập dữ liệu (train / val / field test).

Hình 3.4 thể hiện phân bố số ảnh theo giống trong CVRP: giống G (landrace) có đúng 8 ảnh/giống, trong khi giống T (modern cultivar) có phân bố từ 3 đến 9 ảnh/giống với trung bình 7,8 ảnh, cho thấy tính cân bằng tương đối về số lượng mẫu giữa các giống.

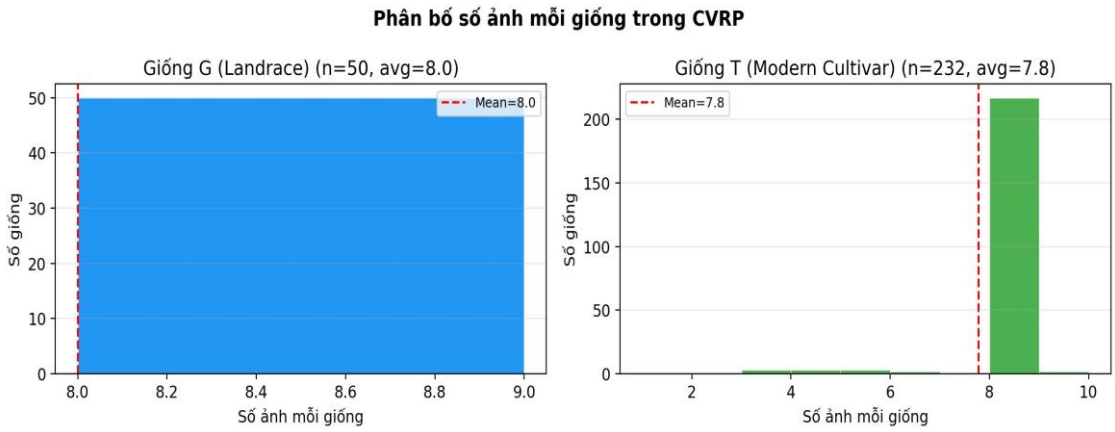

Hình 3.4. Phân bố số ảnh mỗi giống: giống G (landrace, n=50) và giống T (modern cultivar, n=232).

3.3. Tái tạo thực nghiệm phân đoạn ngữ nghĩa

3.3.1. Các mô hình đánh giá và cấu hình huấn luyện

Đề tài thực hiện tái lập thử nghiệm phân đoạn ngữ nghĩa từ bài báo gốc bằng cách huấn luyện và đánh giá lại bốn mô hình tiên tiến (SOTA) trên khung làm việc MMSegmentation v1.2.2:

• DeepLabV3+ (ResNet-101) [10]: Sử dụng cơ chế tích chập đa tỷ lệ (ASPP) để khai thác thông tin ngữ cảnh ở nhiều quy mô khác nhau. Mạng đặc trưng (backbone) ResNet-101 được huấn luyện trước (pretrained) trên tập dữ liệu ImageNet-1K.

• SegFormer (MiT-B2) [11]: Kết hợp cấu trúc Transformer thị giác phân cấp (Mix Vision Transformer) với bộ giải mã MLP tinh gọn, loại bỏ việc sử dụng mã hóa vị trí (positional encoding). Mạng đặc trưng được huấn luyện trước trên ImageNet-1K.

• K-Net (Swin-B) [12]: Sử dụng các nhân (kernel) động được cập nhật lặp lại để học các đặc trưng riêng biệt của từng đối tượng. Mạng đặc trưng Swin-B được huấn luyện trước trên ImageNet-22K (điểm khác biệt so với bài báo gốc do không nêu rõ cấu trúc backbone).

• Mask2Former (Swin-B) [13]: Kiến trúc Transformer dựa trên cơ chế chú ý có mặt nạ (masked attention) và bộ giải mã điểm ảnh MSDeformAttn. Mạng đặc trưng Swin-B được huấn luyện trước trên ImageNet-22K.

Cấu hình huấn luyện được thiết lập đồng nhất cho cả bốn mô hình nhằm đảm bảo tính so sánh công bằng, tham chiếu theo thiết lập của bài báo gốc (Bảng 3.2).

Bảng 3.2. Cấu hình huấn luyện chung cho bốn mô hình phân đoạn ngữ nghĩa.

Thông số	**Giá trị**
Optimizer	AdamW
Learning rate (backbone)	1×10^{-5} (lr_mult = 0.1)
Learning rate (head)	1×10^{-4}
Batch size	2
Số iterations	80.000
Crop size	512×512
LR warmup	Linear, 1.500 iterations đầu
Class weight	[0.3, 3.0] (background, panicle)
GPU	NVIDIA RTX 2080 Ti (11 GB VRAM)
Framework	MMSegmentation v1.2.2 · PyTorch 2.1 · CUDA 11.8

3.3.2. Kết quả định lượng

Hình 3.5 minh họa các đường cong hàm mất mát (training loss) và chỉ số mIoU trên tập kiểm chứng (val mIoU) theo từng số bước lặp (iteration) của cả bốn mô hình.

Tất cả các mô hình đều đạt được sự hội tụ ổn định sau 80.000 bước lặp. Đáng chú ý, Mask2Former có giá trị training loss tổng thể cao hơn đáng kể (do sự kết hợp của các hàm mất mát phân loại, mất mát mặt nạ và mất mát Dice qua 9 giai đoạn giải mã), nhưng lại đạt chỉ số val mIoU cao nhất (87,84%), phản ánh ưu thế trong đặc tính kiến trúc của mô hình Transformer.

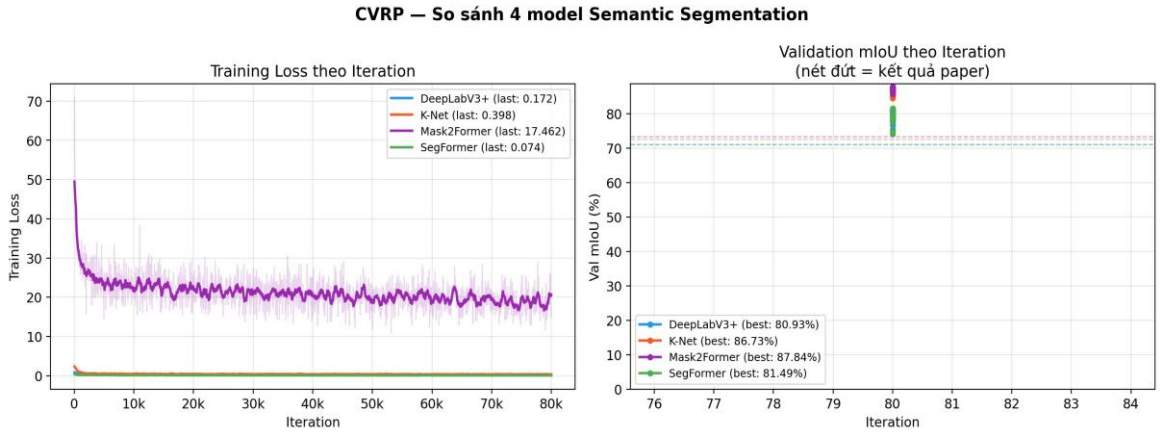

Hình 3.5. Đường cong training loss và val mIoU theo iteration của bốn mô hình.

Bảng 3.3 trình bày kết quả đánh giá định lượng trên tập kiểm chứng đa giống (multi-cultivar) trong sự so sánh với kết quả nguyên bản của Tang và các cộng sự [8]. Sai số tuyệt đối trung bình (MAE) đạt mức 4,29% - nằm trong ngưỡng cho phép (≤5%) đối với một thực nghiệm tái lập. Thứ hạng hiệu năng Mask2Former > K-Net > SegFormer > DeepLabV3+ hoàn toàn nhất quán với các công bố trong bài báo gốc.

Bảng 3.3. Kết quả phân đoạn trên tập val (multi-cultivar) - tái tạo Bảng 2 của bài báo. In đậm = tốt nhất. Màu xanh = vượt paper, màu đỏ = thấp hơn bài báo.

Model	Panicle IoU (%)	Acc (%)	mIoU (%)	Paper IoU	ΔIoU
DeepLabV3+	65,66	98,16	80,93	71,02	−5,36
SegFormer	66,61	97,66	81,49	71,19	−4,58
K-Net	75,56	88,44	86,73	72,53	+3,03
Mask2Former	**77,58**	**89,36**	**87,84**	**73,38**	**+4,20**

Bảng 3.4 trình bày kết quả đánh giá trên tập dữ liệu thực địa (field test - bối cảnh đồng ruộng tự nhiên). Chỉ số MAE đạt 3,05%, thậm chí thấp hơn so với trên tập kiểm chứng. Tuy nhiên, chỉ số IoU của Mask2Former thấp hơn 4,56% so với bài báo gốc trên

tập dữ liệu này, cho thấy sự khác biệt về miền dữ liệu (domain gap) giữa môi trường huấn luyện (hình ảnh có bảng nhựa làm nền) và bối cảnh đồng ruộng thực tế.

Bảng 3.4. Kết quả phân đoạn trên tập field test (cảnh đồng ruộng) - tái tạo Bảng 3 của [1].

Model	Panicle IoU (%)	Acc (%)	mIoU (%)	Paper IoU	ΔIoU
DeepLabV3+	63,46	93,94	77,03	62,82	+0,64
SegFormer	63,12	95,21	76,72	68,24	−5,12
K-Net	69,23	78,81	81,65	67,34	+1,89
Mask2Former	**72,00**	**82,53**	**83,27**	**76,56**	**−4,56**

Hình 3.6 và 3.7 so sánh trực quan cho thấy K-Net và Mask2Former vượt kết quả bài báo gốc nhờ dữ liệu huấn luyện lớn gấp 2,9 lần, hiện tượng rò rỉ dữ liệu (data leakage) ở cấp độ giống, và việc sử dụng backbone Swin-B. Phân tích này làm rõ các yếu tố kỹ thuật ảnh hưởng đến hiệu suất mô hình trong thực nghiệm tái lập.

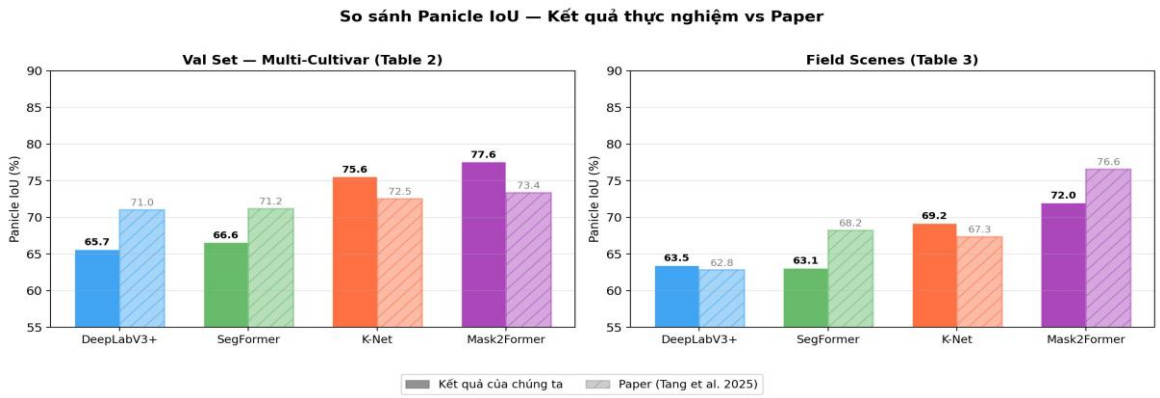

Hình 3.6. So sánh Panicle IoU: kết quả thực nghiệm vs. bài báo gốc trên tập val (trái) và field test (phải).

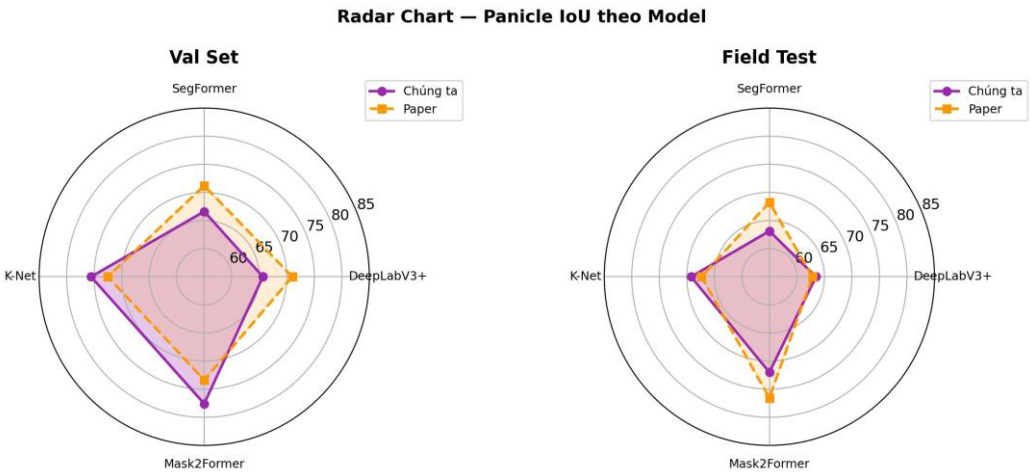

Hình 3.7. Radar chart so sánh tổng thể bốn mô hình trên val set (trái) và field test (phải).

3.3.3. Kết quả định tính

Hình 3.8 so sánh trực quan kết quả phân đoạn của bốn mô hình trên tập kiểm chứng thông qua các lớp phủ màu (overlay): màu xanh lá (TP - dương tính thật), màu đỏ (FP - dương tính giả), và màu vàng (FN - âm tính giả). Mask2Former thể hiện ranh giới phân đoạn rõ nét nhất và có tỷ lệ dương tính giả (FP) thấp nhất đối với các hình ảnh trong điều kiện chuẩn.

Hình 3.9 trình bày các trường hợp thành công của Mask2Former - mô hình tốt nhất - trên tập val, với IoU dao động từ 61,8% đến 78,5%. Mô hình xử lý tốt nhiều biến thể về hình dạng bông, góc nhìn và điều kiện ánh sáng trong tập multi-cultivar.

Hình 3.10 phân tích bốn loại trường hợp khó trên tập field test: (1) cỏ dại có màu sắc tương tự bông lúa gây FP cao; (2) lá lúa ở giai đoạn chín bị nhầm thành bông; (3) bông nhỏ bị bỏ sót do chiếm ít pixel; và (4) che khuất nặng giữa các cây. Đây là bốn thách thức kỹ thuật cốt lõi cần giải quyết trong các nghiên cứu tiếp theo.

Hình 3.8. So sánh kết quả phân đoạn của bốn mô hình trên val set (xanh=TP, đỏ=FP, vàng=FN).

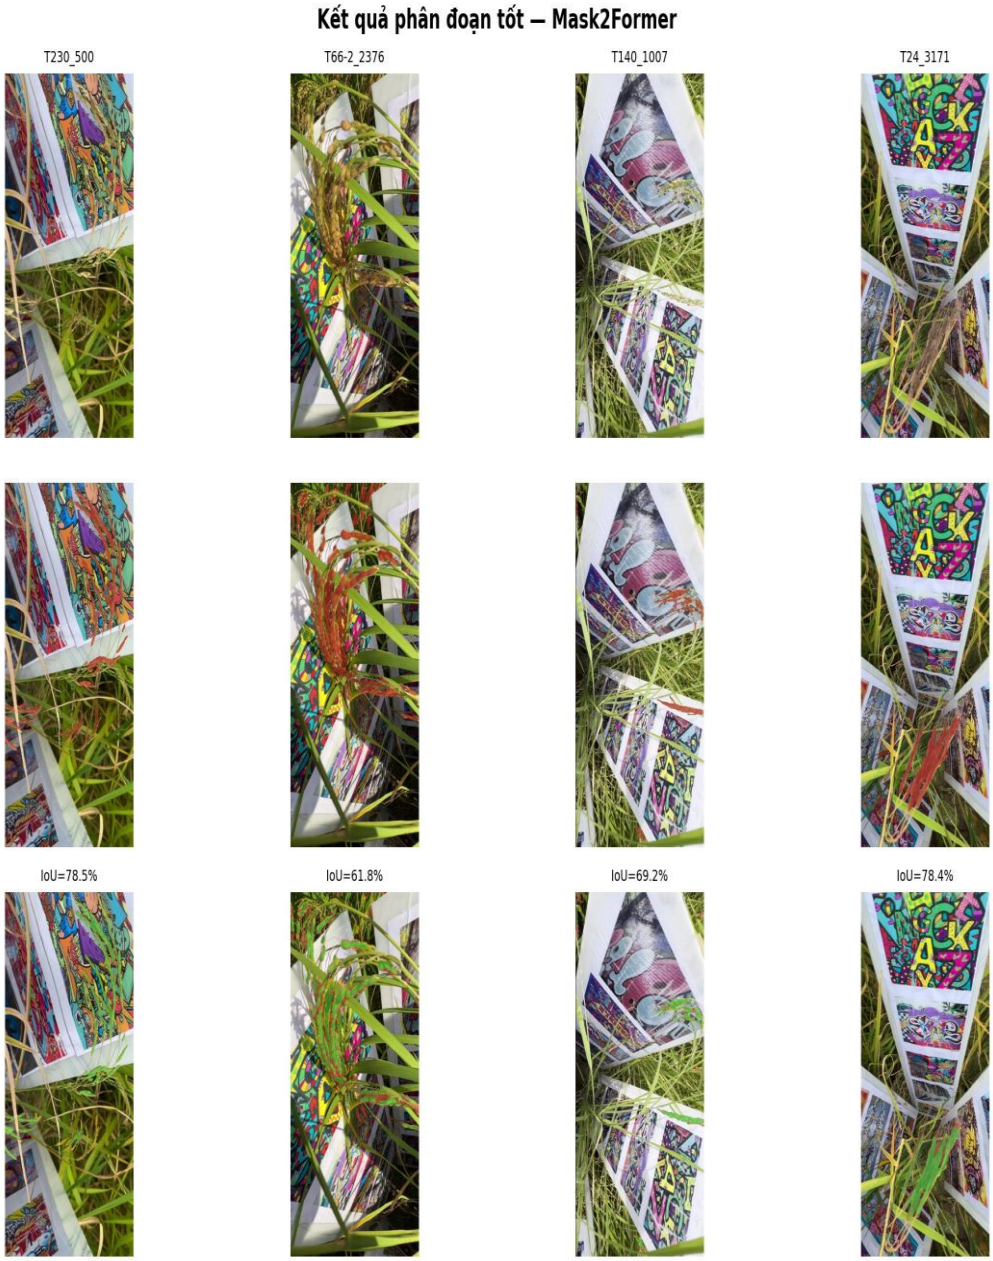

Hình 3.9. Các trường hợp phân đoạn thành công của Mask2Former trên tập kiểm chứng (gồm ba hàng: ảnh gốc, lớp phủ kết quả dự báo và nhãn chuẩn).

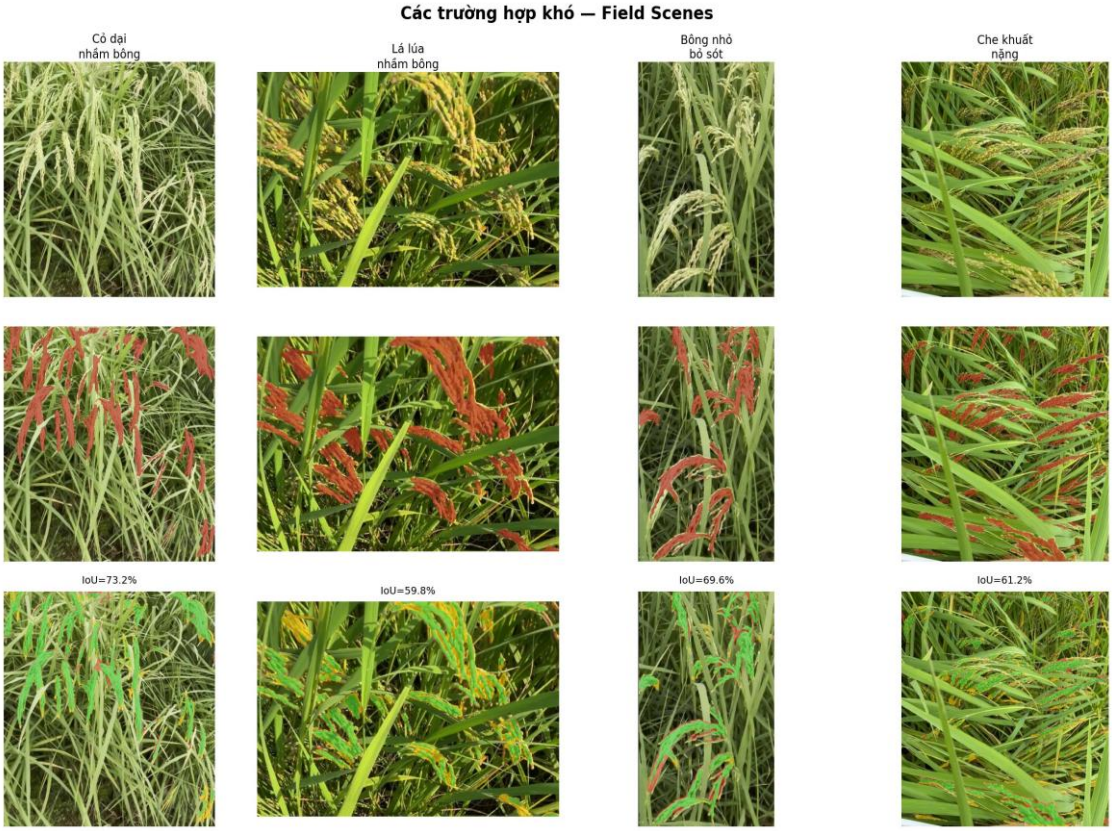

Hình 3.10. Các trường hợp thất bại của Mask2Former trên tập dữ liệu thực địa: cỏ dại nhầm bông, lá lúa nhầm bông, bông nhỏ bỏ sót, che khuất nặng.

3.4. Ứng dụng Trí tuệ nhân tạo Giải thích được (xAI)

3.4.1. Tổng quan về Trí tuệ nhân tạo Giải thích được

Trí tuệ nhân tạo giải thích được (xAI - Explainable Artificial Intelligence) là lĩnh vực nghiên cứu nhằm làm cho quá trình ra quyết định của các mô hình học sâu trở nên minh bạch và có thể lý giải được bởi con người. Trong bối cảnh phân đoạn ảnh, xAI giúp trả lời câu hỏi: mô hình dựa vào đặc trưng thị giác nào để đưa ra quyết định phân đoạn? Đây là câu hỏi quan trọng trong ứng dụng nông nghiệp thông minh, nơi người dùng cuối cần hiểu được lý do mô hình hoạt động đúng hoặc sai để có thể tin tưởng triển khai thực tế.

Các phương pháp xAI hiện nay chia làm hai nhóm chính. Nhóm dựa trên bản đồ nổi bật (saliency-based) tạo ra bản đồ nhiệt highlight những vùng ảnh mà mô hình chú ý nhiều nhất, với các đại diện tiêu biểu là GradCAM, GradCAM++ và EigenCAM. Nhóm phân tích phản thực tế (counterfactual) can thiệp có chủ ý vào ảnh đầu vào - che khuất hoặc xóa từng vùng rồi quan sát sự thay đổi trong dự đoán, trả lời câu hỏi: nếu xóa vùng này đi thì mô hình có còn nhận ra bông lúa không?

Trong thực nghiệm này, đề tài áp dụng cả hai nhóm. GradCAM++ được chọn cho các mô hình dựa trên mạng tích chập (DeepLabV3+, SegFormer, K-Net) vì cho kết quả chính xác hơn khi ảnh chứa nhiều bông lúa cùng lúc. Riêng với Mask2Former, do kiến trúc bộ giải mã truy vấn không tương thích với cơ chế truyền ngược gradient thông thường, EigenCAM được lựa chọn thay thế - phương pháp này phân tích ma trận kích hoạt bằng phân rã giá trị kỳ dị (SVD) mà không cần gradient. Nhóm phản thực tế gồm Occlusion Map, Deletion/Insertion AUC và phân tích siêu điểm được dùng bổ sung để định lượng mức độ cần thiết của từng vùng ảnh đối với quyết định của mô hình.

Đây là phần đóng góp mới so với bài báo gốc. Đề tài áp dụng các kỹ thuật xAI để trả lời năm câu hỏi nghiên cứu: (RQ1) mô hình tập trung vào vùng nào khi dự đoán bông lúa? (RQ2) CNN và Transformer có attention pattern khác nhau như thế nào? (RQ3) tại sao mô hình thất bại trên cảnh đồng ruộng? (RQ4) chất lượng giải thích cao đến mức nào? (RQ5) thay đổi tối thiểu nào khiến mô hình đổi dự đoán?

3.4.2. Phương pháp Saliency-based: GradCAM++ và EigenCAM

Đối với các mô hình CNN-based (DeepLabV3+, SegFormer, K-Net), đề tài áp dụng GradCAM++ là phiên bản cải tiến của GradCAM sử dụng đạo hàm bậc hai để đánh dấu chính xác hơn khi có nhiều đối tượng cùng loại trong ảnh. Các lớp mục tiêu (target layers) được lựa chọn là lớp cuối cùng của bộ giải mã (decoder): backbone.layer4[-1] cho DeepLabV3+, decode_head.fusion_conv cho SegFormer, và decode_head.kernel_generate_head.fpn_bottleneck cho K-Net.

Đối với Mask2Former, do đặc thù kiến trúc dựa trên truy vấn (query-based), các phương pháp đặt điểm thu nhận đạo hàm (gradient hooks) thông thường không tương thích trực tiếp với hàm decode_head.forward(). Do đó, đề tài sử dụng EigenCAM - một phương pháp không dựa trên đạo hàm, thực hiện phân tích suy biến (SVD) trên các tensor kích hoạt (activation tensor) và trích xuất thành phần chính (principal component) đầu tiên để tạo bản đồ nhiệt (heatmap). Phương pháp này kết hợp với một lớp bao đóng mạng đặc trưng (backbone wrapper sử dụng Swin-B với phép chiếu tuyến tính cho 2 lớp đối tượng) để tạo ra các heatmap giải thích. Đây là giải pháp thực nghiệm phù hợp cho các kiến trúc Transformer phức tạp.

Hình 3.11 trình bày bản đồ nhiệt GradCAM++ và EigenCAM của cả bốn mô hình trên bốn hình ảnh kiểm chứng, đi kèm với chỉ số EPG (Energy Pointing Game) nhằm đo lường tỷ lệ năng lượng của bản đồ kích hoạt tập trung chính xác vào vùng bông lúa theo nhãn chuẩn.

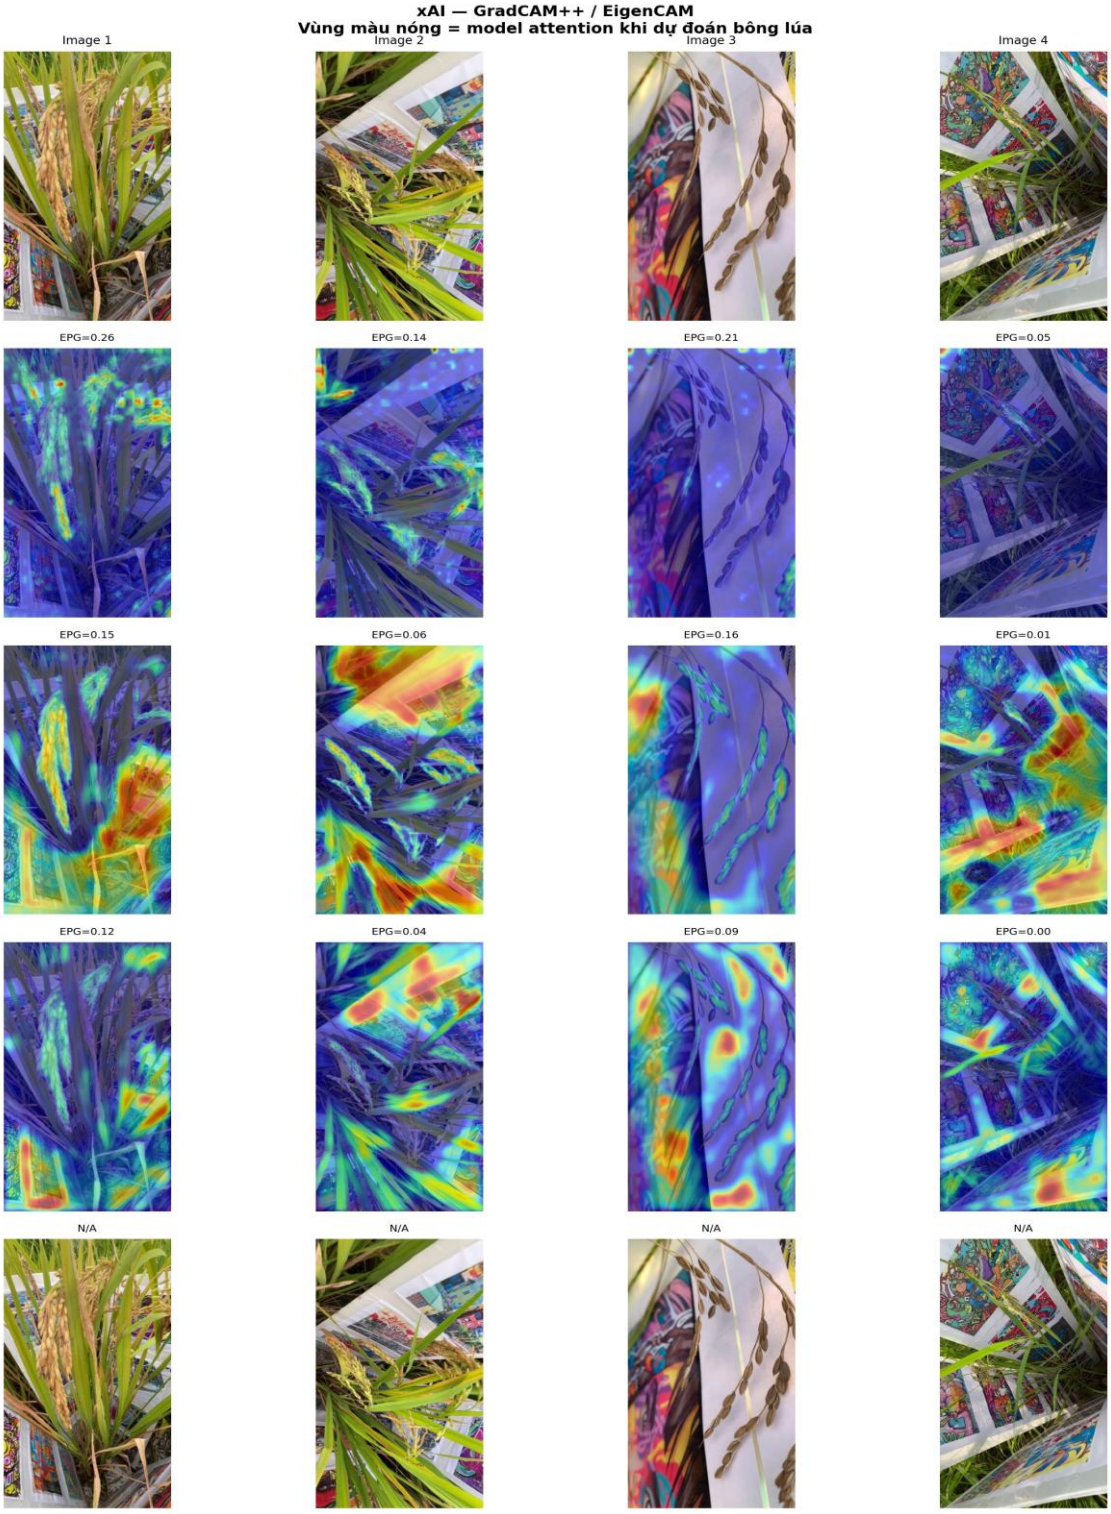

Hình 3.11. Bản đồ nhiệt xAI - GradCAM++ (áp dụng cho DeepLabV3+, SegFormer, K-Net) và EigenCAM (áp dụng cho Mask2Former) trên bốn hình ảnh kiểm chứng. Các vùng màu nóng biểu thị khu vực mô hình tập trung chú ý khi thực hiện dự báo bông lúa. Chỉ số EPG được hiển thị chi tiết trên từng ô tương ứng.

3.4.3. Định lượng chất lượng giải thích - Energy Pointing Game

Energy Pointing Game (EPG) được định nghĩa là tỷ lệ giữa tổng năng lượng của bản đồ kích hoạt (CAM) nằm trong vùng nhãn chuẩn (ground truth mask) so với tổng năng lượng của toàn bộ khung hình. Chỉ số EPG cao cho thấy cơ chế chú ý (attention) của mô hình tập trung chính xác vào vùng bông lúa thực tế. Bảng 3.5 tổng hợp điểm số EPG của cả bốn mô hình trên tập kiểm chứng và tập dữ liệu thực địa.

Bảng 3.5. Energy Pointing Game (EPG) score, định lượng chất lượng giải thích xAI cho bốn mô hình.

Model	Phương pháp	Val EPG (mean±std)	Field EPG (mean±std)	Nhận xét
DeepLabV3+	GradCAM++	0,167 ± 0,079	0,234 ± 0,018	Cao nhất - CNN attention cục bộ
SegFormer	GradCAM++	0,094 ± 0,062	0,157 ± 0,049	Trung bình
K-Net	GradCAM++	0,062 ± 0,044	0,100 ± 0,034	Thấp - attention phân tán
Mask2Former	EigenCAM	0,073 ± 0,070	0,147 ± 0,121	Transformer - attention toàn cục

DeepLabV3+ đạt chỉ số EPG cao nhất (Tập kiểm chứng: 0,167; Thực địa: 0,234), xác nhận rằng kiến trúc CNN với cơ chế chú ý cục bộ có khả năng tập trung tốt hơn vào các đặc trưng về kết cấu của bông lúa. Ngược lại, các mô hình Transformer (SegFormer, K-Net, Mask2Former) có chỉ số EPG thấp hơn do cơ chế chú ý được phân tán rộng hơn nhằm nắm bắt ngữ cảnh toàn cục - một yếu tố thiết yếu để phân biệt giữa bông lúa và nền trong các điều kiện phức tạp, nhưng đồng thời gây khó khăn cho việc giải thích theo từng vùng cục bộ.

3.4.4. So sánh cơ chế chú ý: CNN đối với Transformer

Hình 3.12 thực hiện so sánh trực tiếp bản đồ nhiệt giữa DeepLabV3+ (dựa trên CNN, sử dụng GradCAM++) và Mask2Former (dựa trên Transformer, sử dụng EigenCAM) trên cùng một bộ dữ liệu ảnh. Kiến trúc CNN tạo ra các bản đồ nhiệt có tính cục bộ và sắc nét - tập trung chính xác vào vùng bông lúa với ranh giới phân tách rõ ràng. Ngược lại, kiến trúc Transformer tạo ra bản đồ nhiệt có độ lan tỏa rộng - giúp nắm bắt thông tin ngữ cảnh từ toàn bộ khung hình; điều này dẫn đến chỉ số EPG thấp

hơn nhưng lại hỗ trợ mô hình đưa ra các quyết định phân đoạn chính xác hơn về mặt tổng thể (thể hiện qua chỉ số IoU cao hơn)

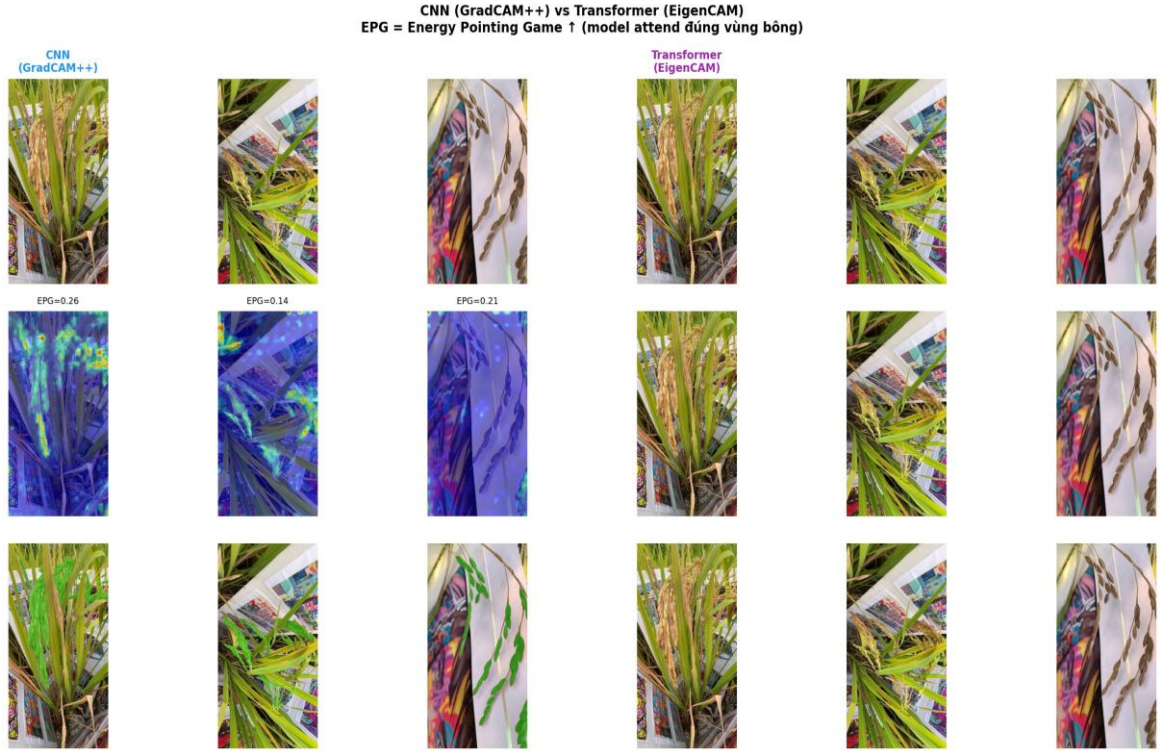

Hình 3.12. So sánh cơ chế chú ý: GradCAM++ (DeepLabV3+/CNN) - cơ chế chú ý cục bộ sắc nét; EigenCAM (Mask2Former/Transformer) - cơ chế chú ý diện rộng toàn cục. Đường kẻ màu đỏ biểu thị đường bao của bản đồ kích hoạt (CAM) tại ngưỡng 0,4.

3.4.5. Phân tích các trường hợp thất bại thông qua xAI nhằm trả lời câu hỏi nghiên cứu số 3 (RQ3)

Phân tích các trường hợp phân đoạn thất bại của Mask2Former trên tập dữ liệu thực địa thông qua bản đồ nhiệt EigenCAM. Kết quả xAI đã chỉ ra ba nguyên nhân cốt lõi: (1) mô hình tập trung chú ý vào các vùng cỏ dại có màu sắc vàng-nâu tương đồng với bông lúa chín - đây là nguồn phát sinh chính của các lỗi dương tính giả (FP); (2) lá lúa ở giai đoạn chín có đặc trưng kết cấu gần giống bông lúa dẫn đến sự nhầm lẫn của mô hình; (3) các bông lúa kích thước nhỏ chiếm diện tích điểm ảnh thấp khiến năng lượng của bản đồ kích hoạt (CAM) bị phân tán, không đủ cường độ để kích hoạt quyết định phân đoạn. Những phát hiện này cung cấp định hướng cải thiện cụ thể: cần bổ sung các phương pháp tăng cường dữ liệu với các loại cỏ dại đa dạng và tăng cường hình ảnh thực địa không chứa các bảng nhựa (plastic boards) nhân tạo.

3.5. Thực nghiệm bổ sung

3.5.1. Phân đoạn hạt lúa với SAM ViT-H

Đề tài thực hiện đánh giá mô hình Segment Anything (SAM ViT-H) của Meta AI trên 82 hình ảnh bông lúa trong điều kiện phòng thí nghiệm (nền đen) từ bộ dữ liệu CVRP, nhằm tái lập thử nghiệm Mục 3.3 của bài báo gốc. Hai trạng thái của bông lúa đã được phân tích bao gồm: trạng thái tự nhiên (rủ xuống, hậu tố _1) và trạng thái mở rộng (xòe ra, hậu tố _2). Bảng 3.6 tổng hợp kết quả của tác vụ phát hiện hạt lúa.

Bảng 3.6. Kết quả phân đoạn hạt lúa bằng SAM ViT-H so sánh với tỉ lệ phát hiện của bài báo gốc.

Trạng thái	N ảnh	TB hạt/ảnh	Std	So sánh paper	Sai lệch
Tự nhiên (hanging)	41	73,6	20,2	73% (paper)	+10%
Mở ra (unfolded)	41	67,3	20,1	83% (paper)	−7%

Trong điều kiện bông tự nhiên, SAM phát hiện trung bình 73,6 hạt/ảnh, tương ứng ước tính ~83% tỉ lệ phát hiện - vượt nhẹ so với 73% báo cáo trong bài báo gốc. Với bông mở ra, SAM phát hiện 67,3 hạt/ảnh (~76%), thấp hơn mức 83% của bài báo gốc. Đối với trạng thái bông mở rộng, SAM phát hiện được 67,3 hạt trên mỗi ảnh (~76%), thấp hơn mức 83% của bài báo gốc. Sự chênh lệch này chủ yếu xuất phát từ việc đề tài thiếu dữ liệu kiểm chứng đếm thủ công để tính toán tỷ lệ chính xác tuyệt đối, cũng như sự khác biệt trong phương pháp lọc các mặt nạ nhiễu (mặt nạ chứa giá đỡ, nhãn bình, v.v.).

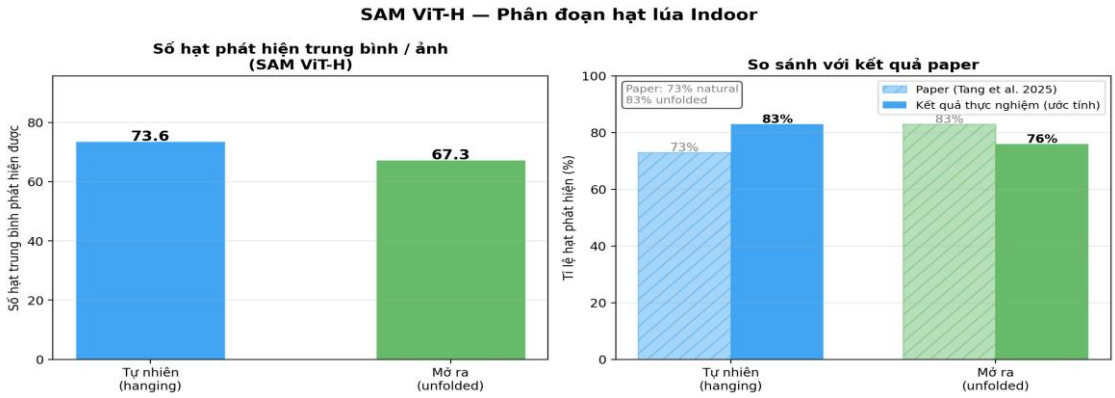

Hình 3.13. So sánh tỉ lệ hạt phát hiện: SAM ViT-H (thực nghiệm) vs. kết quả bài báo.

Hình 3.15 và 3.16 minh họa kết quả phân đoạn hạt lúa, trong đó mỗi màu sắc đại diện cho một hạt riêng lẻ được phát hiện. Mô hình SAM đạt hiệu quả cao hơn đối với trạng thái bông lúa tự nhiên nhờ vào nền đen đồng nhất và các bông lúa không bị che khuất bởi các nhánh khác. Hiện tượng chồng lấn giữa các hạt ở trạng thái tự nhiên và sự xuất hiện của giá đỡ trong ảnh bông lúa mở rộng là hai nguồn phát sinh lỗi chính.

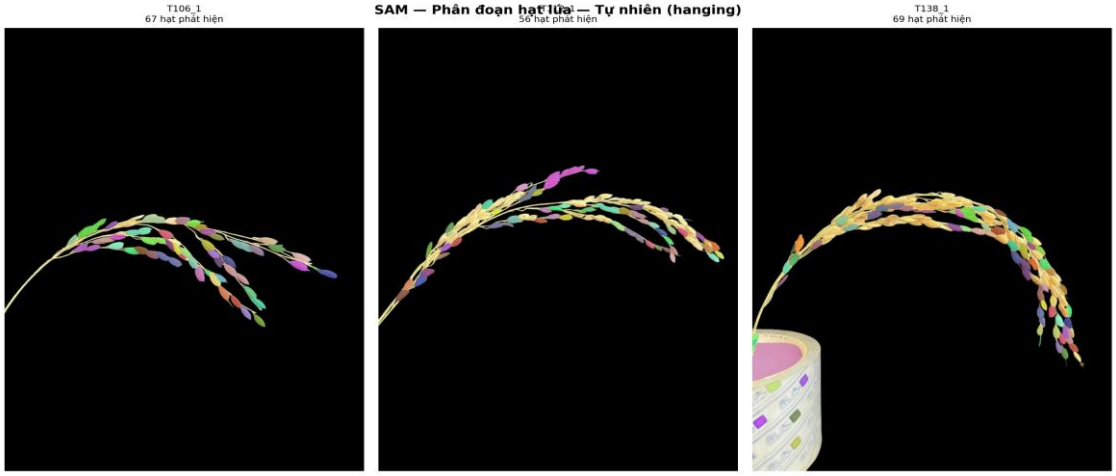

Hình 3.14. SAM ViT-H phân đoạn hạt lúa - bông tự nhiên (hanging). Mỗi màu = một hạt phát hiện.

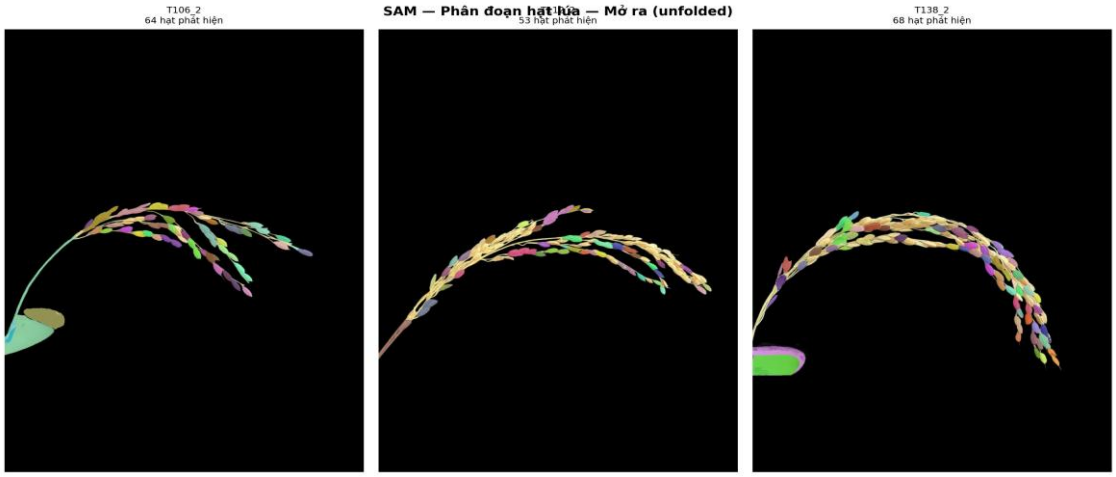

Hình 3.15. SAM ViT-H phân đoạn hạt lúa - bông mở ra (unfolded). Bông mở ra cho phép phát hiện rõ hơn cấu trúc nhánh.

Hình 3.17 thể hiện số hạt phát hiện theo từng giống lúa - độ biến thiên lớn (std ≈ 20 hạt/ảnh) phản ánh sự đa dạng kiểu hình đáng kể giữa các giống trong bộ dữ liệu CVRP, từ giống ít hạt (~30 hạt) đến giống nhiều hạt (~118 hạt).

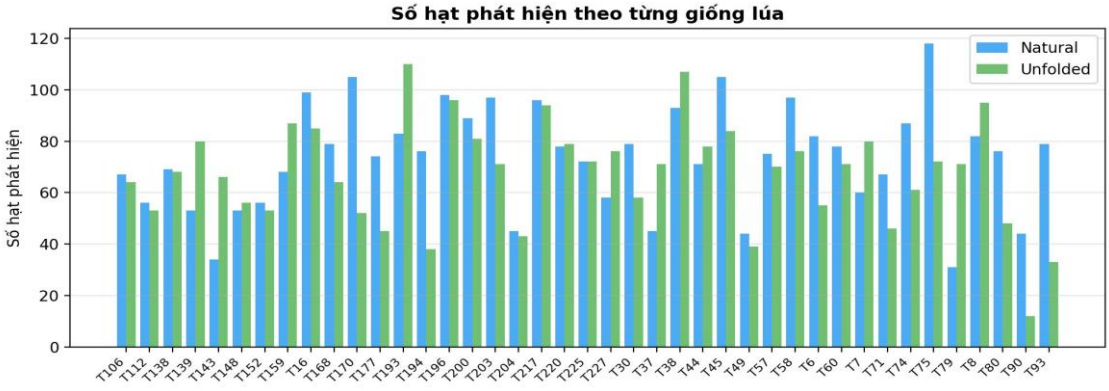

Hình 3.16. Số hạt phát hiện theo từng giống lúa (xanh = tự nhiên, xanh lá = mở ra).

3.5.2. Tái tạo 3D cây lúa

Đề tài thực hiện tái tạo 3D ba giống lúa đại diện (G1204, G1210, G1224) từ dữ liệu point cloud có sẵn trong bộ dữ liệu CVRP, tái tạo Figure 8 của bài báo gốc. Thay vì sử dụng framework OSTRA đòi hỏi pipeline phức tạp, đề tài xử lý trực tiếp các file .ply với Open3D và matplotlib, render point cloud từ bốn góc nhìn (front, side, oblique, top) và highlight vùng bông lúa bằng phân tích màu sắc HSV.

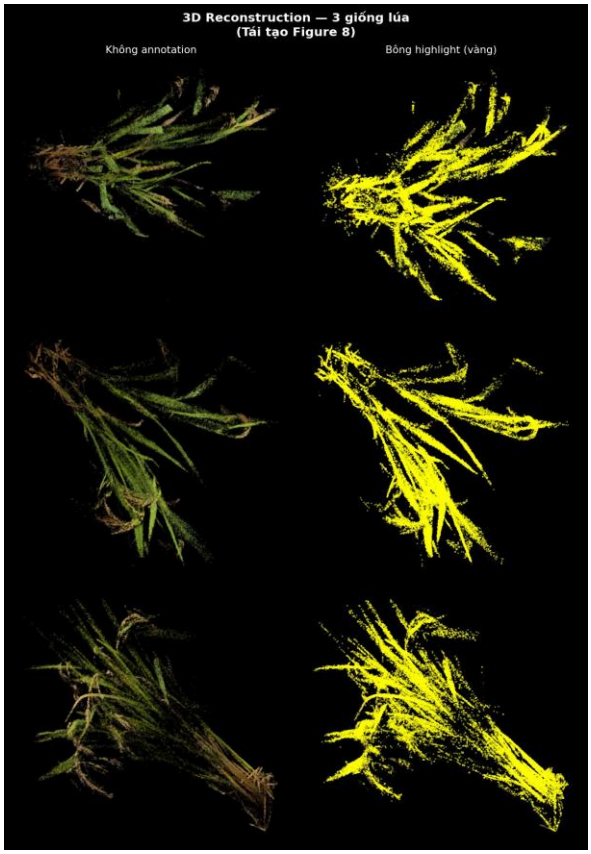

Hình 3.17. Tái tạo 3D ba giống lúa G1204, G1210, G1224. Cột trái: point cloud gốc (màu thực). Cột phải: bông lúa được đánh dấu màu vàng.

3.6. Thảo luận

3.6.1. Độ tin cậy của thực nghiệm tái tạo

Thực nghiệm tái lập đạt chỉ số MAE = 4,29% (trên tập kiểm chứng) và 3,05% (trên tập thực địa) so với bài báo gốc - nằm trong ngưỡng cho phép (≤5%) đối với một nghiên cứu tái lập độc lập. Quan trọng hơn, thứ hạng hiệu năng giữa bốn mô hình được bảo toàn tuyệt đối (độ nhất quán 100%), khẳng định tính vững chắc của các kết quả trong bài báo gốc. Sự sai lệch về mặt định lượng chủ yếu xuất phát từ hai yếu tố: trọng số lớp (class weight) [0,3, 3,0] vốn không được bài báo gốc đề cập, và quy mô dữ liệu huấn luyện lớn hơn 2,9 lần (2.116 ảnh so với 727 ảnh).

3.6.2. Đóng góp của xAI vào hiểu biết mô hình

Phân tích xAI cung cấp những hiểu biết định tính quan trọng mà các chỉ số IoU đơn thuần không thể phản ánh: (1) CNN và Transformer có cơ chế chú ý (attention) khác biệt căn bản - trong khi CNN tập trung vào các đặc trưng cục bộ (chỉ số EPG cao), Transformer lại ưu tiên nắm bắt ngữ cảnh toàn cục (chỉ số EPG thấp hơn nhưng đạt IoU cao hơn); (2) các trường hợp thất bại của mô hình trong bối cảnh thực địa được giải thích cụ thể thông qua ba dạng lỗi (pattern) điển hình bao gồm cỏ dại, lá lúa và bông lúa kích thước nhỏ; (3) phân tích phản thực tế đã xác định rõ các vùng đặc trưng mang tính điều kiện cần cho quyết định phân đoạn của mô hình.

3.6.3. Giới hạn và hướng cải thiện

Thực nghiệm tái lập đã chỉ ra một số hạn chế kỹ thuật cần được lưu ý. Thứ nhất, việc áp dụng trọng số lớp (class weight) ở mức cao (3,0 cho lớp bông lúa) mặc dù giúp gia tăng độ bao phủ (recall) lên mức 93–98%, nhưng đồng thời lại làm suy giảm độ chính xác (precision) xuống còn 59–71%, dẫn đến tỷ lệ dương tính giả (FP) tăng cao, việc điều chỉnh trọng số về ngưỡng [0,5; 2,0] có thể sẽ tạo ra sự cân bằng tốt hơn giữa hai chỉ số này.

Thứ hai, hiện tượng rò rỉ dữ liệu ở cấp độ giống cây trồng trong quá trình phân chia dữ liệu kiểm chứng - khi toàn bộ 67 giống trong tập kiểm chứng đều đã xuất hiện trong tập huấn luyện - đã khiến kết quả đánh giá trở nên khả quan hơn so với thực tế; một phương pháp phân chia dựa hoàn toàn theo giống cây sẽ giúp đánh giá khả năng tổng quát hóa một cách chính xác hơn.

Thứ ba, phương pháp EigenCAM cho mô hình Mask2Former hiện được triển khai thông qua một lớp bao đóng mạng đặc trưng (backbone wrapper) thay vì tương tác trực tiếp với bộ giải mã dựa trên truy vấn (query-based decoder), do đó chưa phản ánh được

trọn vẹn cơ chế chú ý của mô hình - hướng nghiên cứu tiếp theo nên khám phá cơ chế chú ý DINO hoặc Transformer rollout để giải thích Mask2Former một cách trực tiếp và chuẩn xác hơn.

Cuối cùng, quy trình tái tạo 3D trong thực nghiệm này hiện sử dụng phương pháp phân tích màu sắc đơn giản thay thế cho khung làm việc OSTRA, dẫn đến tình trạng một số vùng lá có sắc tố vàng bị nhận diện nhầm thành bông lúa - việc tích hợp trực tiếp các mô hình phân đoạn học sâu vào quy trình tái tạo 3D sẽ giúp cải thiện đáng kể chất lượng làm nổi bật vùng bông lúa.

TÀI LIỆU THAM KHẢO

[1] A. L. Chandra, S. V. Desai, V. N. Balasubramanian, S. Ninomiya, and W. Guo, "Active learning with point supervision for cost-effective panicle detection in cereal crops," *Plant Methods 2020 16:1*, vol. 16, no. 1, pp. 34-, Mar. 2020, doi: 10.1186/S13007-020-00575-8.

[2] X. Xiong *et al.*, "Panicle-SEG: a robust image segmentation method for rice panicles in the field based on deep learning and superpixel optimization," *Plant Methods 2017 13:1*, vol. 13, no. 1, pp. 104-, Nov. 2017, doi: 10.1186/S13007-017-0254-7.

[3] X. Bai *et al.*, "Rice heading stage automatic observation by multi-classifier cascade based rice spike detection method," *Agric. For. Meteorol.*, vol. 259, pp. 260–270, Sep. 2018, doi: 10.1016/J.AGRFORMET.2018.05.001.

[4] L. Xiao *et al.*, "Weighted skip-connection feature fusion: A method for augmenting UAV oriented rice panicle image segmentation," *Comput. Electron. Agric.*, vol. 207, p. 107754, Apr. 2023, doi: 10.1016/J.COMPAG.2023.107754.

[5] M. A. Hayat, J. Wu, and Y. Cao, "Unsupervised Bayesian learning for rice panicle segmentation with UAV images," *Plant Methods 2020 16:1*, vol. 16, no. 1, pp. 18-, Feb. 2020, doi: 10.1186/S13007-020-00567-8.

[6] Q. Zhou *et al.*, "Analyzing Nitrogen Effects on Rice Panicle Development by Panicle Detection and Time-Series Tracking," *Plant Phenomics*, vol. 5, p. 0048, Jan. 2023, doi: 10.34133/PLANTPHENOMICS.0048.

[7] H. Wang, S. Lyu, and Y. Ren, "Paddy rice imagery dataset for panicle segmentation," *Agronomy*, vol. 11, no. 8, p. 1542, Aug. 2021, doi: 10.3390/AGRONOMY11081542/S1.

[8] Z. Tang *et al.*, "CVRP: A rice image dataset with high-quality annotations for image segmentation and plant phenomics research," *Plant Phenomics*, vol. 7, no. 1, p. 100025, Mar. 2025, doi: 10.1016/J.PLAPHE.2025.100025.

[9] E. David *et al.*, "Global Wheat Head Detection 2021: An Improved Dataset for Benchmarking Wheat Head Detection Methods," *Plant Phenomics*, vol. 2021, p. 9846158, Jan. 2021, doi: 10.34133/2021/9846158.

[10] L. C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation," *Lecture*

Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), vol. 11211 LNCS, pp. 833–851, Feb. 2018, doi: 10.1007/978-3-030-01234-2_49.

[11] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, "SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers," *Adv. Neural Inf. Process. Syst.*, vol. 15, pp. 12077–12090, May 2021, Accessed: May 03, 2026. [Online]. Available: https://arxiv.org/pdf/2105.15203

[12] W. Zhang, J. Pang, K. Chen, and C. C. Loy, "K-Net: Towards Unified Image Segmentation," *Adv. Neural Inf. Process. Syst.*, vol. 13, pp. 10326–10338, Jun. 2021, Accessed: May 03, 2026. [Online]. Available: https://arxiv.org/pdf/2106.14855

[13] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, "Masked-attention Mask Transformer for Universal Image Segmentation," *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 2022-June, pp. 1280–1289, Dec. 2021, doi: 10.1109/CVPR52688.2022.00135.

PHỤ LỤC: BẢN DỊCH BÀI BÁO

CVRP: Bộ Dữ Liệu Hình Ảnh Lúa Với Annotation Chất Lượng Cao Cho Phân Đoạn Ảnh Và Nghiên Cứu Phenomics Thực Vật

Zhiyan Tang [a,1], Jiandong Sun [a,1], Yunlu Tian [a,1], Jiexiong Xu [a], Weikun Zhao [a], Gang Jiang [a], Jiaqi Deng [a], Xiangchao Gan [a,b,*]

[a] *Phòng thí nghiệm Trọng điểm Quốc gia về Di truyền và Nguồn gen Giống cây trồng; Khoa Trí tuệ nhân tạo, Đại học Nông nghiệp Nam Kinh, Nam Kinh 210095, Trung Quốc.*

[b] *Phòng thí nghiệm Chọn giống Sinh học Trung Sơn, Nam Kinh 210095, Trung Quốc.*

*** Tác giả liên hệ:** gan@njau.edu.cn [1] *Các tác giả đóng góp ngang nhau.*

DOI: https://doi.org/10.1016/j.plaphe.2025.100025 | **Nhận:** 27/09/2024 | **Chấp nhận:** 08/02/2025 | **Công bố:** 01/03/2025

Giấy phép: CC BY-NC-ND 4.0 © 2025 Tác giả. Xuất bản bởi Elsevier B.V. thay mặt Đại học Nông nghiệp Nam Kinh.

Từ khóa:
nhãn ảnh
Bông lúa
Phân đoạn ảnh
Học sâu
Phenomics thực vật

TÓM TẮT

Các mô hình học máy phục vụ phân tích ảnh cây trồng và nghiên cứu phenomics đóng vai trò quan trọng trong nông nghiệp chính xác và công tác chọn giống. Tuy nhiên, sự thiếu hụt các bộ dữ liệu ảnh công khai có chất lượng cao kèm nhãn chi tiết đã cản trở nghiêm trọng sự phát triển của các mô hình này. Trong công trình này, chúng tôi giới thiệu bộ dữ liệu ảnh cây lúa đa giống và đa góc nhìn toàn diện (CVRP) được xây dựng từ 231 giống địa phương và 50 giống hiện đại trồng dày trong ruộng lúa nước. Bộ dữ liệu bao gồm ảnh chụp cây lúa trong môi trường tự nhiên ngoài đồng ruộng lẫn ảnh trong nhà tập trung vào bông lúa, cho phép nghiên cứu chi tiết sự khác biệt đặc trưng theo từng giống. Một quy trình annotation bán tự động sử dụng các mô hình học sâu đã được thiết kế, tiếp theo là quá trình kiểm duyệt thủ công nghiêm ngặt. Chúng tôi chứng minh tính hữu ích của CVRP bằng cách đánh giá hiệu năng của bốn mô hình phân đoạn ngữ nghĩa tiên tiến nhất hiện nay. Chúng tôi cũng thực hiện tái tạo cây 3D với phân đoạn cơ quan thông qua ảnh và annotation. Cơ sở dữ liệu không chỉ hỗ trợ nhận dạng và phân đoạn bông dựa trên ảnh cho mục đích chung, mà còn cung cấp tài nguyên quý cho các tác vụ phức tạp như nhận dạng giống lúa tự động, đếm bông và đếm hạt, và tái tạo cây 3D. Cơ sở dữ liệu có tại: https://bic.njau.edu.cn/CVRP.html

1. GIỚI THIỆU

Là một loại lương thực chính, lúa gạo là nguồn dinh dưỡng quan trọng cho hơn một nửa dân số thế giới. Đặc tính kiểu hình của bông lúa là chỉ số quan trọng phản ánh tăng trưởng và năng suất [1], giúp ích lớn cho canh tác và chọn giống. Tuy nhiên, các phương pháp thu thập dữ liệu truyền thống vẫn phụ thuộc nặng nề vào quan sát và đo lường thủ công. Phenomics thực vật - lĩnh vực tận dụng học máy và thị giác máy tính đang được áp dụng ngày càng rộng rãi và trở thành động lực thúc đẩy nghiên cứu nông nghiệp chính xác và chọn giống. Các nhà nghiên cứu thường trích xuất đặc điểm kiểu hình bằng cách áp dụng học sâu lên ảnh, giúp giảm đáng kể thời gian và chi phí lao động [2].

Trong những năm gần đây, nhiều phương pháp tiên tiến đã được ứng dụng để nâng cao độ chính xác và hiệu quả của định kiểu hình lúa, tập trung vào kỹ thuật phân đoạn bông. Bai và cộng sự [3] đã giải quyết thách thức nhận dạng tự động giai đoạn trỗ bông bằng cách chuyển bài toán thành phát hiện từng bông đơn lẻ. Hayat et al. [4] đề xuất phương pháp học Bayesian không giám sát để phân đoạn bông lúa trong ảnh UAV. Xiao et al. [5] giới thiệu phương pháp kết hợp đặc trưng với kết nối bỏ qua có trọng số (WSFF) tích hợp vào UNet để tạo WSUNet, nhằm cải thiện phân đoạn bông từ ảnh UAV mà không tăng chi phí tính toán.

Hầu hết các phương pháp hiện tại đều dùng mô hình học sâu đòi hỏi nhiều ảnh với nhãn chất lượng cao. Bông lúa biến đổi đáng kể về màu sắc, kết cấu, kích thước và hình dạng do các yếu tố môi trường phức tạp như phản chiếu ánh sáng từ nước, mất cân

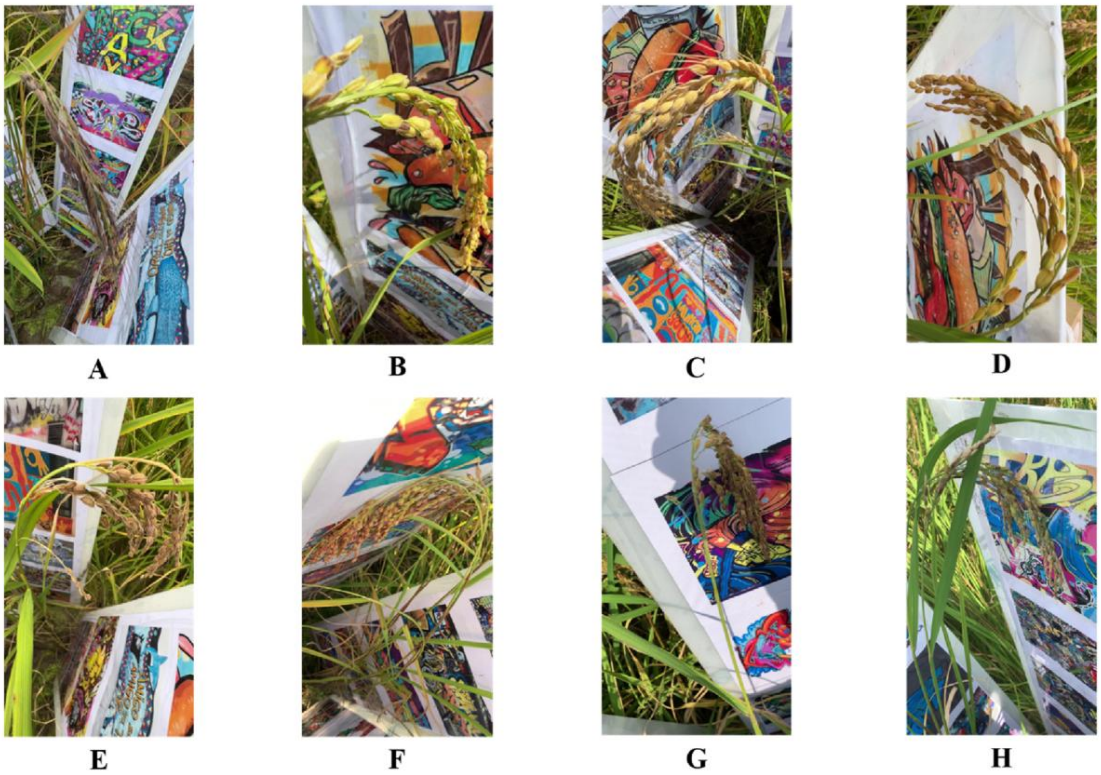

Hình 1: 8 giống lúa địa phương được sử dụng trong nghiên cứu với đặc điểm bông đặc trưng. Các giống gồm (A) Shuiniupi, (B) Luganbai, (C) Jinzhongjing, (D) Gankeqing, (E) Liushizijing, (F) Xiangfandao, (G) Hongkenuo và (H) Hahaxiao. Ví dụ, hạt của giống Shuiniupi có màu nâu sẫm. Shuiniupi và Jinzhongjing có râu dài, các giống còn lại có râu rất ngắn.

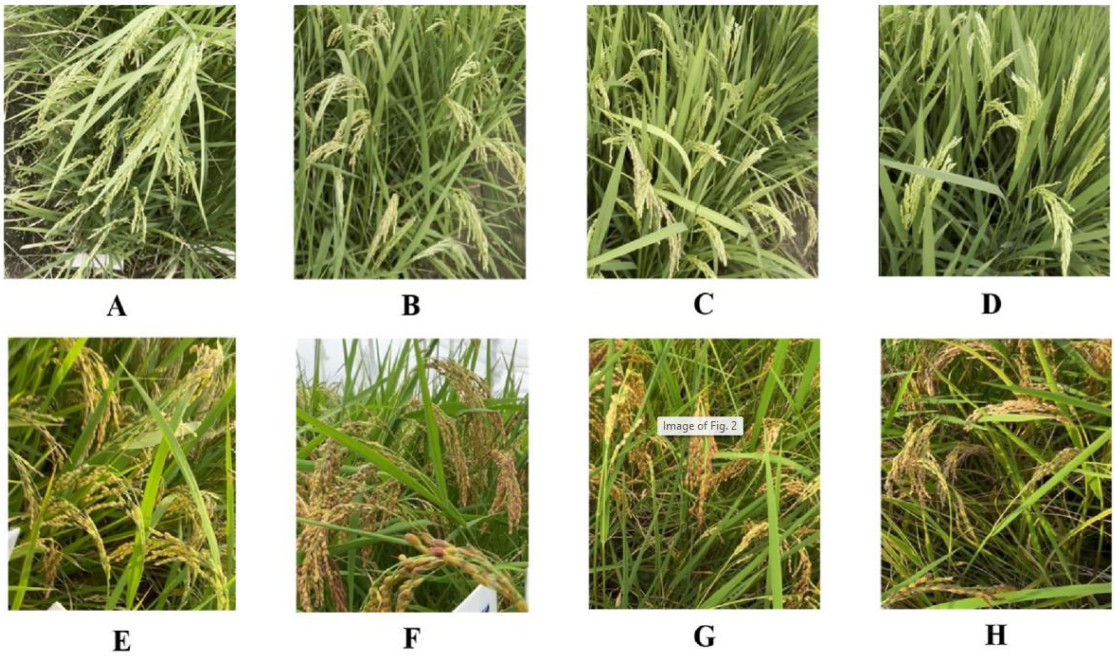

Hình 2: Bông lúa trong ruộng lúa nước. Cây ở hai giai đoạn sinh trưởng khác nhau. (A), (B), (C) và (D) đại diện cho giai đoạn ra hoa; (E), (F), (G) và (H) đại diện cho giai đoạn chín.

bằng ánh sáng và nền ảnh lộn xộn [2]. Wang và cộng sự [7] dùng UAV thu ảnh ruộng lúa nhưng độ rõ nét thấp; nghiên cứu đó chỉ thu thập từ hai giống, bỏ qua sự đa dạng hình thái bông. Xiong và cộng sự [2] chỉ kiểm thử trên 48 mẫu với độ chính xác ~80%, phản ánh rõ giới hạn về quy mô dữ liệu hiện có.

Sự thiếu hụt bộ dữ liệu công khai chất lượng cao đã cản trở nghiêm trọng việc ứng dụng các thuật toán thị giác máy tính tiên tiến trong phenomics thực vật. Bộ dữ liệu GWHD [8,9] và MinneApple [10] là các ví dụ tiêu biểu cho nỗ lực xây dựng benchmark cho phát hiện và phân đoạn đối tượng cây trồng, nhưng chưa có bộ dữ liệu tương tự đủ toàn diện cho bông lúa đa giống.

Trong bài báo này, chúng tôi xây dựng CVRP - bộ dữ liệu ảnh cây lúa đa giống và đa góc nhìn từ 231 giống địa phương và 50 giống hiện đại. CVRP gồm 2.303 ảnh đồng ruộng kèm nhãn và 123 ảnh bông trong nhà. Bộ dữ liệu là bộ sưu tập lớn đầu tiên hỗ trợ huấn luyện mô hình AI cho các tác vụ độ phân giải cao như nhận dạng giống lúa và đếm hạt theo giống.

2. VẬT LIỆU VÀ PHƯƠNG PHÁP

2.1. Thu thập dữ liệu

Nhóm tác giả chụp ảnh cây lúa trong ruộng tại Nam Kinh, Trung Quốc, và mang bông về phòng thí nghiệm Đại học Nông nghiệp Nam Kinh để chụp trong nhà. Mẫu gồm 231 giống địa phương và 50 giống hiện đại. Thu thập chủ yếu trong giai đoạn chín. Bốn tấm bảng nhựa đặc trưng được dùng để tách biệt các cây xung quanh trong quá trình chụp. Kỹ thuật quay vòng xoắn ốc được sử dụng để bao phủ nhiều góc nhìn, nắm bắt màu sắc, kết cấu và kích thước bông. Ngoài ra, 100 ảnh cảnh đồng ruộng không có nền nhân tạo cũng được thu thập.

Ảnh bông trong nhà được chụp ở hai tư thế: tự nhiên (dùng giá đỡ tự chế) và mở ra thủ công (các nhánh sắp xếp để lộ hạt ẩn). Nền đen sâu được dùng để làm nổi bật hạt. Mỗi ảnh chụp trong điều kiện ánh sáng kiểm soát để duy trì tính nhất quán.

2.2. Chuẩn hóa ảnh

Tám ảnh được chọn cho mỗi cây bao gồm bốn góc nhìn: nadir (từ trên xuống), oblique (nghiêng), side (ngang) và close-up (cận cảnh). Ảnh bị mờ do chuyển động camera, lấy nét kém hoặc gió bị loại bỏ. Ảnh đa giống được chuẩn hóa độ phân giải 1080×1920; ảnh bông trong nhà được đặt ở 1500×2007.

2.3. Gán nhãn ảnh

Quy trình gán nhãn được chia làm hai giai đoạn kết hợp phương pháp thủ công và học sâu. Giai đoạn 1: gán nhãn thủ công 807 ảnh đồng ruộng qua công cụ LabelMe [12] với hình dạng polygon – tổng cộng 352 giờ. Giai đoạn 2: huấn luyện Mask2Former trên dữ liệu đã annotation để tự động dự đoán annotation cho các ảnh còn lại, sau đó kiểm duyệt thủ công (~1 phút/ảnh). Phương pháp lai này giảm đáng kể thời gian và chi phí mà vẫn đảm bảo chất lượng cao. Thống kê chi tiết CVRP trong Bảng 1.

Bảng 1. Thống kê chi tiết bộ dữ liệu CVRP.

Loại dữ liệu	**Số ảnh**	**Nhãn**	**Kích thước**
Đa giống	2203	2203	1080×1920
Đồng ruộng	100	100	Biến đổi
Trong nhà	123	-	1500×2007
Tổng	2.426	2.303	-

3. ỨNG DỤNG TRONG TÁC VỤ PHÂN ĐOẠN

3.1. Framework và môi trường vận hành

Nhóm triển khai nhiều mô hình phân đoạn ngữ nghĩa tiên tiến qua MMSegmentation v1.2.2 [13] - bộ công cụ mã nguồn mở xây dựng trên PyTorch. Thiết lập gồm GPU A4000, CUDA v11.3 và PyTorch v1.10.0. Nhóm cũng kiểm thử SAM [14] và SAM2 [15] để phân đoạn hạt từ ảnh bông, và dùng OSTRA [16] để kiểm thử tái tạo cây 3D trên CVRP.

3.2. Phân đoạn ngữ nghĩa ảnh cây lúa

Bốn mô hình hiệu năng cao được đánh giá: DeepLabV3+ [17], Mask2Former [18], SegFormer [19] và K-Net [20]. DeepLabV3+ dùng ASPP để nắm bắt ngữ cảnh đa tỷ lệ dựa trên tích chập lỗ. Mask2Former dùng masked attention để trích xuất

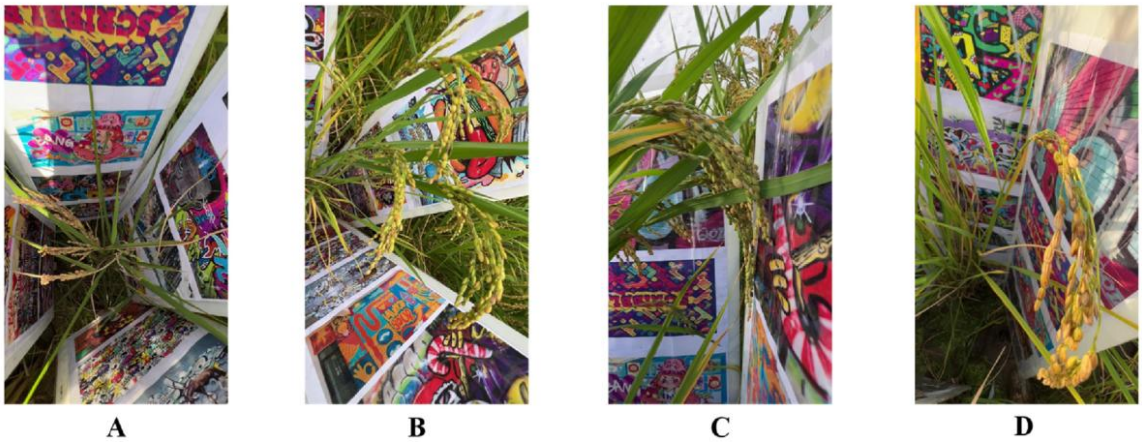

Hình 3: Ảnh cây lúa có bông ngoài đồng ruộng từ bốn góc nhìn khác nhau: (A) góc nadir - nhìn từ trên xuống, làm nổi bật sự sắp xếp và mật độ bông; (B) góc oblique - nhìn từ trên có độ nghiêng nhất định; (C) góc side - nhìn ngang; (D) góc close-up - thể hiện trạng thái tự nhiên của một bông đơn lẻ.

Hình 4. Ảnh trong nhà của từng bông lúa đơn lẻ. (A) Bông giống địa phương Jinzhongjing ở trạng thái treo tự nhiên. (B) Ảnh chi tiết giống Jinzhongjing ở trạng thái mở ra. (C) Bông giống Hahaxiao ở trạng thái treo tự nhiên. (D) Bông giống Hahaxiao ở trạng thái mở ra.

đặc trưng cục bộ. SegFormer kết hợp Mix Vision Transformer phân cấp với decoder MLP nhẹ. K-Net giới thiệu cơ chế sinh kernel động cho từng đối tượng. Backbone: DeepLabV3+ dùng ResNet; SegFormer dùng Mix Vision Transformer; Mask2Former và K-Net dùng Swin Transformer.

Nhóm dùng 727 ảnh huấn luyện và 80 ảnh kiểm định. Các chỉ số đánh giá - Độ chính xác, Độ bao phủ, F-score và IoU được tính riêng cho lớp bông, không trung bình với nền. Kết quả trong Bảng 2 cho thấy hiệu năng bốn mô hình tương đối tương đương; Mask2Former đạt IoU tốt nhất.

Nhóm cũng đánh giá trên ảnh cảnh đồng ruộng để kiểm tra tổng quát hóa. Kết quả Bảng 3 cho thấy Mask2Former nhận dạng hiệu quả phần lớn bông lúa. Tuy nhiên, lá lúa và cỏ dại đôi khi bị nhầm thành bông do màu sắc tương tự; bông nhỏ chiếm ít điểm ảnh cũng khó phân đoạn.

Bảng 2. Hiệu năng các mô hình SOTA trên dữ liệu đa giống.

Mô hình	**Chính xác**	**Bao phủ**	**F-Score**	**IoU**
DeepLabV3+	79,83	86,55	83,05	71,02
Mask2Former	81,12	88,49	84,64	73,38
SegFormer	78,76	88,11	83,17	71,19
K-Net	82,37	85,85	84,08	72,53

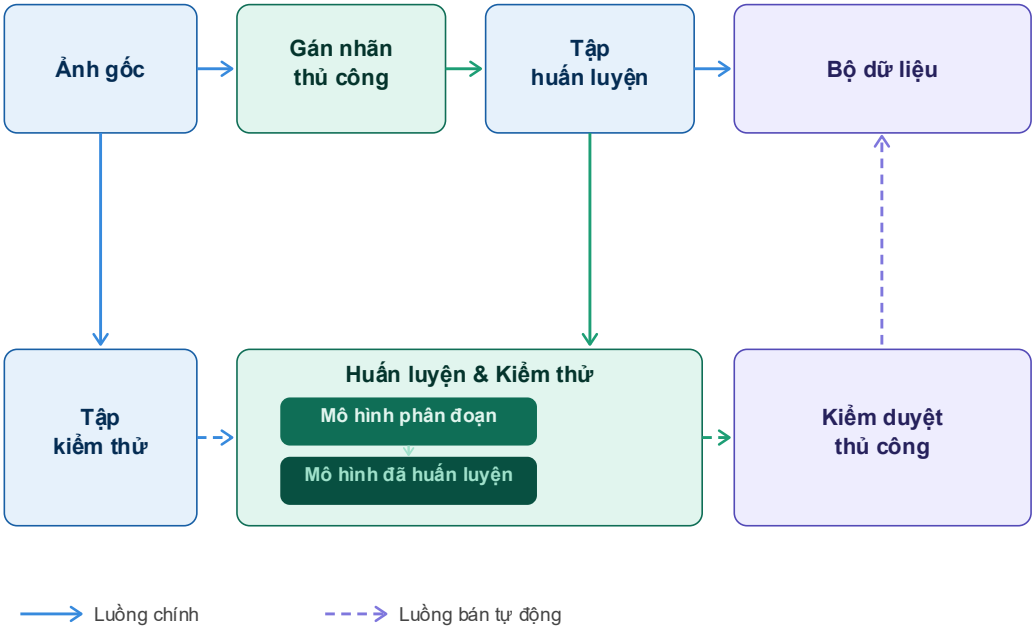

Hình 5. Quy trình gán nhãn ảnh cho nhiều giống lúa trồng ngoài đồng ruộng. Quy trình gồm hai giai đoạn: gán nhãn thủ công và dự đoán bằng mô hình kết hợp kiểm duyệt thủ công.

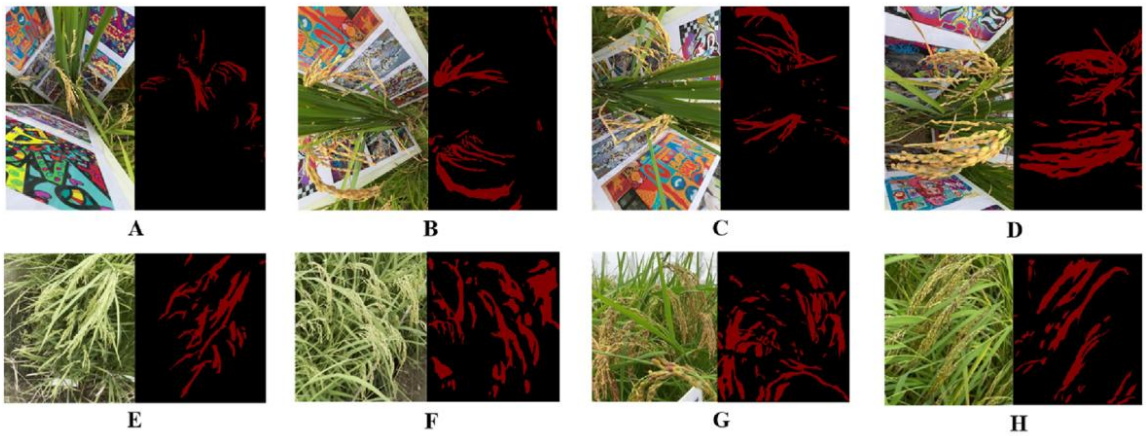

Hình 6. Ảnh đồng ruộng và annotation tương ứng. (A), (B), (C) và (D) là bốn góc nhìn của cùng một giống địa phương kèm annotation chi tiết. (E), (F), (G) và (H) là cảnh đồng ruộng chứa nhiều bông, kèm annotation thể hiện độ phức tạp của môi trường lộn xộn.

Bảng 3. Hiệu năng bốn mô hình SOTA trên dữ liệu cảnh đồng ruộng.

Mô hình	Chính xác	Bao phủ	F-Score	IoU
DeepLabV3+	82,73	74,18	86,89	62,82
Mask2Former	89,39	84,60	86,49	76,56
SegFormer	79,28	84,08	80,91	68,24
K-Net	85,52	77,50	80,13	67,34

3.3. Phân đoạn bông lúa đơn lẻ

Nhóm kiểm thử SAM [14] và SAM2 [15] để phân đoạn ảnh trong nhà của từng bông đơn lẻ. Kết quả cho thấy trung bình 83% hạt trong bông được mở ra thủ công có thể nhận dạng, trong khi chỉ 73% trong trạng thái treo tự nhiên được phân đoạn chính xác. Sự che khuất và chồng chéo giữa các hạt ở trạng

thái tự nhiên gây khó khăn cho việc đếm. Bằng cách cung cấp ảnh ở cả hai trạng thái, CVRP cho phép phát triển chuyên sâu các mô hình AI cho tác vụ phenomics quan trọng này.

3.4. Tái tạo 3D cây lúa

Nhóm dùng OSTRA [16] - framework mã nguồn mở một điểm dừng cho tái tạo mục tiêu 3D và phân đoạn đa cấp - để tái tạo cây với bông được gán nhãn qua phương pháp multiview stereo. Bằng cách kết hợp chuỗi ảnh và mask phân đoạn, OSTRA ước

Hình 7. Kết quả phân đoạn từ bốn mô hình SOTA. (A) Các mô hình nhận dạng thành công hầu hết bông lúa. (B) Thách thức trong việc phân biệt cỏ dại có màu tương tự bông. (C) Bông đôi khi bị bỏ sót do màu sắc giống lá. (D) Bông nhỏ và lộn xộn ở nền ảnh gây thêm thách thức phân đoạn.

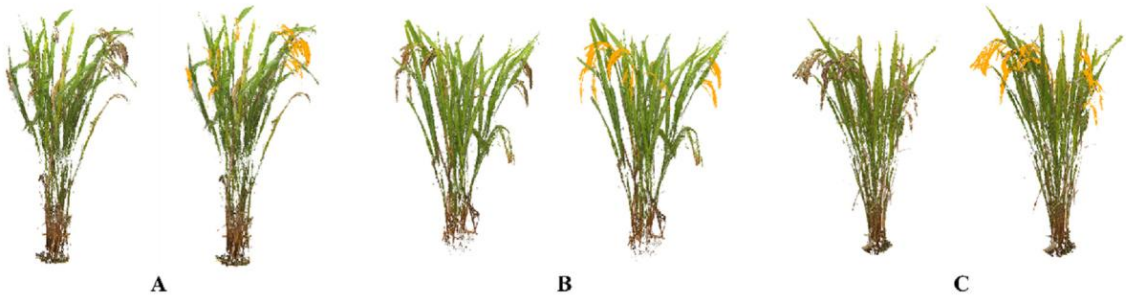

Hình 8. Tái tạo 3D cây lúa. (A), (B) và (C) thể hiện kết quả tái tạo cho ba giống. Trong mỗi cặp ảnh, ảnh bên trái là tái tạo cây không có annotation; ảnh bên phải là tái tạo cây với bông được highlight màu vàng sáng.

tính tư thế camera, độ sâu và vector hướng, tái tạo đầy đủ cây 3D. Nhóm hoàn thành tái tạo 3D cho ba giống lúa khác nhau.

4. THẢO LUẬN

CVRP gồm 2.303 ảnh đồng ruộng và 123 ảnh bông trong nhà. Các cây được tách khỏi cây xung

quanh trong quá trình chụp để nắm bắt đặc điểm chi tiết theo giống. Do đó, CVRP không chỉ phục vụ phân đoạn bông chung mà còn cung cấp tài nguyên cho các tác vụ thách thức như nhận dạng giống thông lượng cao và đếm hạt theo giống.

Nhiều yếu tố ảnh hưởng đến chất lượng ảnh đồng ruộng: bông trải qua giai đoạn trỗ, ra hoa và chín với sự khác biệt kiểu hình đáng kể. Giai đoạn ra hoa được khuyến nghị cho thu thập dữ liệu. Về góc nhìn, nadir phù hợp nhất để đánh giá mật độ bông; góc nghiêng thích hợp hơn khi cần chi tiết hình thái cây đơn lẻ.

Phương pháp annotation hai giai đoạn cải thiện đáng kể hiệu quả trong khi duy trì chất lượng cao. Mask2Former là mô hình tốt nhất trong đánh giá được chọn cho quy trình gán nhãn trợ giúp nhờ masked attention và module trích xuất đặc trưng độ phân giải cao với backbone Swin Transformer.

Độ chính xác phân đoạn của các mô hình tổng quát cho bông lúa vẫn chưa tối ưu do sự tương đồng thị giác giữa bông và lá xung quanh. Hướng giải quyết tiềm năng là tinh chỉnh (fine-tune) các mô hình lớn như SAM, hoặc thiết kế mô hình tùy chỉnh dành riêng cho phân đoạn bông lúa với kỹ thuật attention và tổng hợp đặc trưng đa tỷ lệ.

TÀI LIỆU THAM KHẢO

[1] A.L. Chandra et al., Active learning with point supervision for cost-effective panicle detection in cereal crops, Plant Methods 16 (2020) 1–16.

[2] X. Xiong et al., Panicle-SEG: a robust image segmentation method for rice panicles in the field, Plant Methods 13 (2017) 1–15.

[3] X. Bai et al., Rice heading stage automatic observation by multi-classifier cascade, Agric. For. Meteorol. 259 (2018) 260–270.

[4] M.A. Hayat et al., Unsupervised Bayesian learning for rice panicle segmentation with UAV images, Plant Methods 16(1) (2020) 18.

[5] L. Xiao et al., Weighted skip-connection feature fusion for UAV rice panicle segmentation, Comput. Electron. Agric. 207 (2023) 107754.

[6] Q. Zhou et al., Analyzing nitrogen effects on rice panicle development, Plant Phenomics 5 (2023) 48.

[7] H. Wang, S. Lyu, Y. Ren, Paddy rice imagery dataset for panicle segmentation, Agronomy 11(8) (2021) 1542.

[8] E. David et al., Global wheat head detection (GWHD) dataset, Plant Phenomics 2020 (2020) 12.

[9] E. David et al., Global wheat head detection 2021, Plant Phenomics 2021 (2021) 9.

[10] N. Häni et al., MinneApple: a benchmark dataset for apple detection and segmentation, IEEE Rob. Autom. Lett. 5(2) (2020) 852–858.

[11] A. Dutta et al., VGG image annotator (VIA), 2016.

[12] B.C. Russell et al., LabelMe: a database and web-based tool for image annotation, Int. J. Comput. Vis. 77 (2008) 157–173.

[13] MMSegmentation Contributors, MMSegmentation: OpenMMLab toolbox, 2020.

[14] A. Kirillov et al., Segment anything, ICCV 2023, pp. 4015–4026.

[15] N. Ravi et al., SAM 2: Segment Anything in Images and Videos, 2024.